



VYSOKÉ UČENÍ TECHNICKÉ V BRNĚ

BRNO UNIVERSITY OF TECHNOLOGY

FAKULTA INFORMAČNÍCH TECHNOLOGIÍ

FACULTY OF INFORMATION TECHNOLOGY

ÚSTAV POČÍTAČOVÉ GRAFIKY A MULTIMÉDIÍ

DEPARTMENT OF COMPUTER GRAPHICS AND MULTIMEDIA

FRAMEWORK PRO MODELOVÁNÍ A PREDIKCI UDÁLOSTÍ VE FOTBALE.

FRAMEWORK FOR EVENT MODELING A PREDICTION IN FOOTBALL.

DIPLOMOVÁ PRÁCE

MASTER'S THESIS

AUTOR PRÁCE

AUTHOR

Bc. Maroš Geffert

VEDOUCÍ PRÁCE

SUPERVISOR

Ing. Igor Szőke, Ph.D.

BRNO 2024

Zadání diplomové práce



156692

Ústav: Ústav počítačové grafiky a multimédií (UPGM)
Student: **Geffert Maroš, Bc.**
Program: Informační technologie a umělá inteligence
Specializace: Strojové učení
Název: **Framework pro modelování a predikci událostí ve fotbale.**
Kategorie: Zpracování signálů
Akademický rok: 2023/24

Zadání:

1. Prostudujte dostupné techniky a přístupy pro modelování událostí ve fotbale.
2. Prozkoumejte možnosti získávání dat a získejte dostupná data fotbalových událostí. Data analyzujte a rozdělte na části vhodné pro trénování statistických modelů.
3. Navrhněte a implementujte statistické modely pro predikci vývoje fotbalových událostí. Modely průběžně vyhodnocujte.
4. Zhodnoťte výsledky a navrhněte směry dalšího vývoje.
5. Vyrobite A2 plakátek a cca 30 vteřinové video prezentující výsledky vaší práce.

Literatura:

- Exploiting sports-betting market using machine learning, Ondřej Hubáček a Gustav Šír, International Journal of Forecasting 35(2), 2019
- Predicting The Dutch Football Competition Using Public Data: A Machine Learning Approach, Niek Tax, 2015
- Sports match prediction model for training and exercise using attention-based LSTM network, Qiyun Zhang, Xuyun Zhang, Hongsheng Hu, Caizhong Li, Yinping Lin, Rui Ma, Digital Communications and Networks, 2021
- Dále dle pokynů vedoucího

Při obhajobě semestrální části projektu je požadováno:
Body 1, 2 a část bodu 3 ze zadání.

Podrobné závazné pokyny pro vypracování práce viz <https://www.fit.vut.cz/study/theses/>

Vedoucí práce: **Szőke Igor, Ing., Ph.D.**
Vedoucí ústavu: Černocký Jan, prof. Dr. Ing.
Datum zadání: 1.11.2023
Termín pro odevzdání: 17.5.2024
Datum schválení: 29.11.2023

Abstrakt

Táto diplomová práca sa zaoberá skúmaním súčasných metód predikcie futbalových udalostí ako sú počet gólov v zápase, výsledok zápasu, alebo či oba tímy skórujú. Analyzované boli modely neurónová sieť, RandomForest a XGBoost. V rámci práce boli zhromaždené rozsiahle historické dáta o zápasoch a hráčoch. Hlavným cieľom bolo zistiť, či podrobné štatistiky výrazne ovplyvňujú predikciu, zhodnotiť efektivitu využívania stávkových kurzov ako príznakov, preskúmať vplyv historických dát na kvalitu predikcií a zistiť, či je možné s takýmito modelmi dosiahnuť úspech na stávkovom trhu. Výsledky preukázali, že detailné štatistiky zlepšujú presnosť predikcií, avšak používanie kurzov ako príznakov vo všeobecnosti predikcie zhoršuje. Výsledky týkajúce sa využitia historických dát na predikcie boli nejednoznačné. Modely RandomForest a neurónová sieť dosiahli sľubné výsledky s návratnosťou investície 32.38% a 29.04%.

Abstract

This thesis investigates current methods of predicting football events such as the number of goals in a match, the outcome of a match, or whether both teams will score. The models analyzed were neural network, RandomForest and XGBoost. Extensive historical data on matches and players were collected as part of the work. The main objectives were to determine whether detailed statistics significantly affect prediction, to evaluate the effectiveness of using betting odds as features, to investigate the impact of historical data on the quality of predictions, and to determine whether success can be achieved in the betting market with such models. The results showed that detailed statistics improve the accuracy of the predictions, but the use of odds as features generally degrades the predictions. The results regarding the use of historical data for predictions were inconclusive. RandomForest and neural network models achieved promising results with ROI of 32.38% and 29.04%, respectively.

Kľúčové slová

futbal, analýza športových dát, štatistické metódy v športe, predpovedanie futbalových udalostí, prediktívne modelovanie, neurónové siete, rozhodovacie stromy

Keywords

football, sports data analysis, statistical methods in sports, football event prediction, predictive modelling, neural networks, decision trees

Citácia

GEFFERT, Maroš. *Framework pro modelování a predikci událostí ve fotbale*. Brno, 2023. Diplomová práce. Vysoké učení technické v Brně, Fakulta informačních technologií. Vedoucí práce Ing. Igor Szóke, Ph.D.

Framework pro modelování a predikci událostí ve fotbale

Prehlásenie

Prehlasujem, že som túto prácu vypracoval samostatne pod vedením Ing. Igora Szőkeho Ph.D. Uviedol som všetky literárne pramene, publikácie a iné zdroje, z ktorých som čerpal.

.....

Maroš Geffert

9. mája 2024

Podakovanie

Chcel by som sa poďakovať svojmu vedúcemu, Ing. Igorovi Szőkemu Ph.D. za odborné vedenie a rady pri písaní tejto práce.

Obsah

1	Úvod	3
2	Pozadie modelovania futbalových udalostí	5
2.1	Kľúčové udalosti a pravidlá futbalu	5
2.2	Analýza futbalu, ako predmet predikcie	6
2.3	Prístupy v predikčných úlohách vo futbale	8
2.3.1	Výber predikčných udalostí	8
2.3.2	Vysvetlenie hodnotiacich metrík v oblasti predikcie športu	9
2.3.3	Modelovanie prostredníctvom pravdepodobnostného rozdelenia	9
2.3.4	Modelovanie prostredníctvom klasifikácie	11
2.3.5	Analýza sociálnych sietí a ich význam pre predikciu futbalových výsledkov	12
2.4	Analýza použitých predikčných modelov	12
2.4.1	Analýza a aplikácia modelu Random Forest	14
2.4.2	Analýza a aplikácia modelu XGBoost	15
2.4.3	Analýza a aplikácia modelu neurónová sieť	16
2.4.4	Analýza a aplikácia modelu neurónová sieť s konvolučnými vrstvami	18
2.5	Analýza príznakov	19
2.5.1	Systém hodnotenia Elo	19
2.5.2	Systém hodnotenia PageRank	20
2.5.3	Odhad premennej očakávaných gólov	20
2.5.4	Stávkové kurzy	22
2.6	Výhoda domáceho tímu	23
3	Dáta	27
3.1	Pôvod dát	27
3.2	Konštrukcia dátovej sady	28
3.3	Prehľad dátovej sady	29
3.4	Kategórie modelov podľa vstupu	30
3.4.1	Jednoduchý model	30
3.4.2	Pokročilý model	30
3.5	Rozdelenie dát pri tréningu	31
4	Návrh a implementácia systému	33
4.1	Základné predikčné modely	34
4.2	Implementované predikčné modely	34
4.2.1	Schéma predikčných modelov systému	34
4.2.2	Spracovanie štatistík hráčov pomocou konvolúcie	35

4.2.3	Architektúra a tréovanie neurónovej siete	36
4.2.4	Konfigurácia modelu RandomForest	39
4.2.5	Konfigurácia modelu XGBoost	40
4.3	Transformácia pozápasových štatistík	41
4.4	Porovnanie charakteristík rôznych futbalových líg	41
4.5	Optimalizácia štruktúry dát	41
4.5.1	Výber príznakov na základe korelácie	42
4.5.2	Metóda postupnej selekcie	42
4.6	Riešenie problému chýbajúcich dát	43
5	Experimentálny dizajn a ciele	45
5.1	Hodnotiace metriky	45
5.1.1	Presnosť a jej interpretácia	45
5.1.2	Návratnosť investície	46
5.1.3	Brierovo skóre	46
5.1.4	Metrika podobnosť bookmakera	47
5.2	Vyhodnotenie modelov	47
5.3	Hodnotenie v porovnaní s kurzovými stávkami	48
6	Vyhodnotenie experimentov	49
6.1	Vplyv historických dát na presnosť predikcií	49
6.2	Analýza vplyvu kurzov na predikčnú efektivitu a ziskovosť modelov	52
6.3	Vyhodnotenie predikčných modelov	56
7	Záver	63
7.1	Budúci vývoj	63
	Literatúra	65
	A Matica štatistík hráčov	69
	B Tabuľka príznakov na úrovni tímov	70

Kapitola 1

Úvod

Futbal, často označovaný, ako „kráľovský šport“, je viac než len hra. Je to fenomén, ktorý ovplyvňuje kultúru, ekonomiku a spoločnosť na celom svete. S miliónmi fanúšikov sledujúcimi zápasy v reálnom čase, futbalové kluby, manažéri a investori neustále hľadajú spôsoby, ako získať konkurenčnú výhodu na ihrisku aj mimo neho. Jedným z kľúčových nástrojov v tejto snahe je schopnosť predpovedať výsledky a udalosti vo futbalových zápasoch s vysokou presnosťou.

V minulosti sa predikcie často zakladali na intuícii a skúsenostiach trénerov alebo analytikov. Avšak v ére digitalizácie sa predikčné modely stávajú sofistikovanejšími. Vývoj technológie umožnil prístup k obrovským dátovým sadám, ktoré obsahujú informácie o každom pohybe hráča, každom odohranom zápase a dokonca aj o atmosférických podmienkach počas zápasu.

Neurónové siete, náhodné lesy, metóda podporných vektorov a poissonové modely predstavujú len niektoré z pokročilých modelov, ktoré sa v súčasnosti využívajú na analýzu futbalových dát [20]. Tieto modely sľubujú nielen vyššiu presnosť, ale aj schopnosť odhaliť skryté vzory a korelácie, ktoré by mohli uniknúť tradičným analytickým prístupom.

Okrem výberu vhodného modelu je kľúčová aj otázka výberu dát. Zatiaľ čo niektoré modely vychádzajú zo základných dát, iné sa zameriavajú na detailné informácie o konkrétnych zápasoch a hráčoch. Táto diverzita prístupov vedie k zásadným otázkam: Ktoré dáta sú relevantnejšie pre predikciu? Je lepšie zameriavať sa na široký prehľad, alebo detailnú analýzu? Ako môžeme znižovať vplyv náhody na výsledky? Zohrávajú staršie dáta rovnako dôležitú úlohu ako aktuálne informácie?

V tejto práci sa zameriavam na zodpovedanie kľúčových otázok a na preskúmanie ďalších zaujímavých aspektov. Mojim hlavným cieľom je poskytnúť ucelený pohľad na niektoré aktuálne metódy predikcie futbalových udalostí, pričom dôkladne identifikujem ich silné a slabé stránky. Pokúsim sa tiež navrhnúť najefektívnejšie riešenia pre rôzne situácie. Zameriavam sa nielen na teoretickú analýzu, ale aj na praktické uplatnenie týchto modelov, najmä v oblasti športových stávk, kde ich efektívnosť má priamy finančný dopad. S ohľadom na potenciál využitia modelov na trhu so športovými stávkami, dôkladne skúmam ich výkonnosť, hodnotím ich na základe trhových kurzov a ziskovosti.

V kontexte narastajúceho záujmu o športové stávkovanie a dôležitosti ochrany ľudí pred veľkými finančnými stratami, pri súčasnom zachovaní radosti z tejto aktivity, ktorá výrazne obohacuje zážitok zo sledovania futbalu, je moja práca aktuálna a relevantná. Verím, že moje zistenia prinesú nové poznatky a inovatívne metódy, ktoré budú formovať budúcnosť analýzy futbalu. Je dôležité zdôrazniť, že táto práca zahŕňa množstvo anglických termínov,

pre ktoré v slovenčine neexistuje úplne ustálený ekvivalent. S cieľom zachovať konzistentnosť a jasnosť textu som sa rozhodol niektoré z týchto výrazov ponechať v anglickom jazyku.

V kapitole 2 sa zameriavam na štruktúru a kľúčové pravidlá futbalu. Ďalej sa budem venovať porovnaniu dvoch najčastejšie používaných prístupov. Predstavím aj klasifikačné modely, s ktorými budem pracovať, a podrobne rozoberiem jednotlivé typy príznakov, ich dôležitosť a význam v kontexte futbalu, ktorý je pre úspešné predpovedanie kľúčový. V kapitole 3 sa zameriam na pôvod a spracovanie dát. Kapitola 4 je venovaná návrhu systému a popisu rôznych modelov, ktoré skúmam v mojej práci. Kapitola 5 sa venuje podrobnému popisu experimentov, ktorých výsledky a hodnotenie nájdete v kapitole 6.

Kapitola 2

Pozadie modelovania futbalových udalostí

Modelovanie futbalových udalostí predstavuje fascinujúce skúmanie, kde sa stretáva vášeň pre šport s analytickou precíznosťou dátovej vedy. Pred zahájením podkapitoly je dôležité pochopiť, že základom úspešného modelovania futbalových udalostí je komplexné pochopenie športu spolu s efektívnym využitím dostupných dát a analytických nástrojov. V tejto práci sa zameriam na analýzu najpoužívanějších modelov pre túto doménu s dôkladným výberom príznakov pre predikciu.

2.1 Kľúčové udalosti a pravidlá futbalu

V tejto časti sa stručne predstavia základné pravidlá futbalu, rozličné udalosti počas zápasu, výsledky, ktoré môžu nastať a sú dôležité pre pochopenie tejto práce.

Základné pravidlá futbalu

Futbal je súťaž medzi dvoma tímami, každým s 11 hráčmi, a trvá 90 minút. Každý tím má na svojej strane ihriska bránku, kam sa snaží skórovať. Tím získa 1 bod za každý gól, ktorý skóruje. Tím s vyšším počtom bodov na konci hry je víťazom, a v prípade rovnakého počtu gólov zápas končí remízou.

Štruktúra domácich líg

Bežne každá európska krajina má domácu ligu, kde sa kluby stretávajú v súťažných zápasoch. Liga zvyčajne pozostáva z 20, alebo 18 tímov, pričom každý tím hrá s každým iným dvakrát - doma a vonku. Za víťazstvo v zápase získava tím 3 body, za remízu získavajú oba tímy po 1 bode. Tím s najvyšším počtom bodov na konci sezóny je víťazom ligy. Zvyčajne 3 tímy s najhorším počtom bodov na konci sezóny vypadáva z ligy.

Kľúčové udalosti zápasu

- **Góly:** Hlavným cieľom futbalu je skórovať viac gólov ako súper. Gól je zaznamenaný, keď lopta prekročí bránkovú čiaru.
- **Strely na bránu:** Strely predstavujú pokusy hráčov o skórovanie gólu. Tieto môžu byť vykonané rôznymi spôsobmi, vrátane kopov, hlavičiek a iných techník.

- **Prihrávky:** Prihrávky sú základným mechanizmom pre prenos lopty medzi spoluhráčmi s cieľom udržať kontrolu nad loptou a vytvoriť si príležitosti na skórovanie.
- **Trestné kopy a voľné kopy:** Tieto udalosti nastávajú po fauloch. Voľný kop sa vykonáva z miesta faulu, zatiaľ čo penaltu udelenú za faul vo vnútri šestnástky vykonáva hráč zo vzdialenosti 11 metrov od bránky.
- **Karty:** Rozhodcovia udelením žltých a červených kariet signalizujú hráčom a tímom porušenie pravidiel. Žlté karty slúžia ako varovanie, zatiaľ čo červené karty vedú k vylúčeniu hráča zo zápasu.
- **Ofsajdy:** Ofsajd (z anglického offside) je porušenie pravidiel hry, kedy v momente prihrávky je útočiaci hráč ku ktorému smeruje prihrávka za predposledným hráčom brániaceho tímu (posledný hráč je väčšinou vždy brankár). Po ofsajde sa hra preruší a loptu má brániaci tím.
- **Striedania** Počas zápasu je možné hráčov vystriedať, ale „len“ piatich počas celého zápasu.
- **Typy hráčov** Hráči sú klasifikovaní do štyroch základných typov: brankári, obrancovia, záložníci a útočníci. Každý z týchto typov hráčov má svoju špecifickú úlohu na ihrisku. Napriek tomu moderný futbal často prekračuje tieto tradičné hranice, čo vedie k situácii, kde hráči rôznych pozícií môžu vymieňať úlohy alebo ich kombinovať.

2.2 Analýza futbalu, ako predmet predikcie

Cieľom analýzy športových výkonov je poskytnutie taktickej alebo funkčnej výhody tímu alebo jednotlivému hráčovi. Táto analýza je taktiež využívaná pre tvorbu kurzov stávkových kancelárií. Dosahuje sa to hodnotením výkonnosti hráčov a tímov pred zápasom, počas zápasu a po zápase. Využívajú sa pri tom relevantné historické štatistické dáta.

Definícia problému


Táto práca sa zameriava na predikciu futbalových udalostí, konkrétne na počet gólov, či obe tímy dajú gól a výsledok stretnutia. V futbale môže počet gólov kolísať v rozmedzí od 0 až po 9 alebo 10, čo robí predikciu tejto metriky náročnou. Rovnako, výsledok stretnutia môže byť buď výhra domácich, hostí, alebo remíza. Na zjednodušenie analýzy a predikcie sa prevedú tieto problémy do binárnej klasifikácie. Pri predikcii celkového počtu gólov v zápase môžeme stanoviť klasifikačnú hranicu x , ktorá určuje, či bude počet gólov menej alebo viac ako určitá hodnota. Hranica x sa vypočíta podľa vzorca $x = 0.5 + g$, kde g je prirodzené číslo vrátane nuly (t.j. $g \in \mathbb{N}_0$ a $g \geq 0$). Napríklad, ak chcem klasifikovať, či bude počet gólov viac ako 2, nastavím $g = 2$, čím získam rozhodovaciu hranicu $x = 2.5$. Toto rozdelenie znamená, že ak je počet gólov maximálne 2, považujeme predikciu za „menej“, zatiaľ čo 3 alebo viac gólov znamená „viac“, keďže počet gólov je vždy celočíselný.

V kontexte predpovedania výsledkov futbalových zápasov symbol **1** indikuje výhru domáceho tímu, **2** predstavuje výhru hostujúceho tímu a remíza je označená ako písmeno **X**. Táto konvencia, široko prijímaná stávkovými kanceláriami, umožňuje efektívnu binárnu klasifikáciu výsledkov. Domáca výhra je zachovaná ako **1**, zatiaľ čo kombinácia **X2** signalizuje, že zápas neskončí výhrou domáceho tímu, čiže buď remízou alebo výhrou hostí. Analogicky,

1X označuje buď výhru domácich alebo remízu, a čistá výhra hostí je reprezentovaná číslom 2.

Výber vhodných príznakov je ďalším kľúčovým krokom v procese predikcie. Je dôležité zistiť, ktoré príznaky, či už sú to štatistiky zo zápasu, alebo dáta o hráčoch, prispievajú k presnosti predikcie. Rovnako je potrebné rozlišovať medzi aktuálnymi a historickými dátami. Tieto úvahy vedú k dvom hlavným hypotézam, ktoré som si stanovil. Prvá hypotéza predpokladá, že historické dáta by nemali mať významný vplyv na predikciu, keďže hráči, ktorí reprezentovali tím napríklad v roku 2017, už nemusia byť jeho členmi v roku 2023, čím by sa naučené parametre stali zastaranými. Podľa druhej hypotézy sa predpokladá, že predpovede výsledkov medzi dvomi tímami T_1 a T_2 budú menej presné, ak sú modely založené výhradne na základných atribútoch (napríklad priemerný počet gólov tímov, identifikátory tímov, dátum zápasu či príslušná liga). Naopak, očakáva sa zvýšenie presnosti pri modeloch, ktoré sú trénované na podrobných štatistikách súvisiacich s predikovanými udalosťami. Tento rozdiel v presnosti je pravdepodobne spôsobený schopnosťou detailných štatistík lepšie zachytiť špecifické trendy a charakteristiky tímov.

Rôznorodosť v štýloch hry a taktikách, ktorá je výsledkom unikátnych stratégií a zloženia hráčov každého tímu, sa týmto spôsobom prejavuje aj v rozdieloch výsledkov. Príkladom tejto diverzity sú rozdiely v priemernom počte gólov medzi ligami, kde sa môžu výsledky líšiť až o jeden celý gól.



Obrázok 2.1: Priemerný počet gólov za sezónu v jednotlivých ligách. Ukazuje rozmanitosť jednotlivých líg.

2.3 Prístupy v predikčných úlohách vo futbale

Predikcia udalostí vo futbale je zložitý problém, ktorý môže byť riešený rôznymi prístupmi. Každý prístup má svoje výhody a nevýhody, a voľba správneho prístupu môže výrazne ovplyvniť presnosť a použiteľnosť vytvorených predikčných modelov. V tejto časti sa preberú dve kľúčové metodiky, ktoré sa uplatňujú pri definovaní predikčných úloh v oblasti futbalu. Predikovanie udalostí založené na pravdepodobnostných rozdeleniach a klasifikácia futbalových udalostí. Cieľom je identifikovať kľúčové výhody a nevýhody každého prístupu, a poskytnúť odporúčania pre vývoj efektívnych predikčných modelov vo futbale.

2.3.1 Výber predikčných udalostí

Existuje široké spektrum udalostí, ktoré je možné predikovať v oblasti futbalu. Od konečného výsledku zápasu po špecifické udalosti, ako gól konkrétneho hráča, alebo udelenie karty. Vzhľadom na rozsah možností je nevyhnutné pre túto prácu vybrať len limitovaný počet udalostí. Pre moju prácu som sa rozhodol sústrediť na nasledujúce udalosti:

- Výsledok zápasu (VYS)
- Oba tímy dajú gól (ODG)
- Počet gólov viac ako 2.5 (V/M 2.5)

Vybral som si tieto udalosti, pretože sú medzi najčastejšími v kontexte futbalu a stávkovania. Taktiež v spojitosti s týmito udalosťami existuje veľké množstvo dostupných dát, čo umožňuje ich efektívnu analýzu a predikciu. Voľba hranice 2.5 gólu pre udalosť „počet gólov viac ako 2.5“ bola vybraná na základe analýzy grafu 2.2, ktorý zobrazuje priemerný počet gólov na zápas v posledných 12 sezónach siedmich najlepších futbalových líg sveta, zahrnujúc približne 27 000 zápasov. Priemerný počet gólov bol 2.74, čo umožňuje približne rovnomerné rozdelenie tried pre binárnu klasifikáciu.



Obrázok 2.2: Distribúcia celkového počtu gólov na zápas ukazuje, že najčastejší počet gólov v zápase sa pohybuje okolo 1 až 4. Červená prerušovaná čiara značí priemer celkového počtu gólov na zápas.



2.3.2 Vysvetlenie hodnotiacich metrík v oblasti predikcie športu

Pri skúmaní a porovnávaní rôznych prediktívnych modelov v oblasti športu je kľúčové porozumieť významu základných hodnotiacich metrík, najmä presnosti (viz. sekcia 5.1.1) a návratnosti investície (ROI¹) (viz. sekcia 5.1.2). V kontexte športových udalostí sa presnosť javí, ako relatívna metrika.

Presnosť a jej relatívnosť Presnosť, napriek tomu, že je často uvádzaná, ako kľúčový ukazovateľ, môže byť zavádzajúca, ak distribúcia tried nie je rovnomerná. Pri predikcii udalosti „v zápase padne aspoň jeden gól“, kde priemerný počet gólov na zápas je podľa grafu 3.1 medzi 2.5 a 3.5, môže aj jednoduchý model, ktorý stále tipuje padnutie gólu, dosiahnuť vysokú presnosť. Naopak, existujú modely s nižšou celkovou presnosťou, ktoré však vynikajú v identifikácii menej pravdepodobných udalostí s vysokými kurzami, čím potenciálne dosahujú vyššiu ROI.

Pohľad bookmakera Bookmaker optimalizuje svoje modely s cieľom maximalizovať presnosť predikcií, a teda aj nastavenie kurzov. Kurzy sa však dynamicky menia v reakcii na jednotlivé stávky ľudí, čo môže viesť k situáciám, kde kurz neodráža maximalizáciu skutočnej pravdepodobnosti výsledku, ale skôr strategické rozhodnutia bookmakera zamerané na maximalizáciu zisku. Tento jav môže umožniť predikčným modelom „poraziť“ bookmakera z hľadiska presnosti tým, že identifikujú hodnotu v kurzoch, ktoré boli umelo upravené.

Zhrnutie Existujú dva základné prístupy k predikcii výsledkov športových zápasov. Prvým je snaha predpovedať výsledky presnejšie než bookmakeri na všetkých zápasoch, čo je však náročná úloha s ohľadom na odbornú analýzu a zdroje informácií, ktoré má bookmaker k dispozícii. Druhým prístupom je identifikácia a využitie trhových nekonzistencií, kde kurz neodráža skutočnú pravdepodobnosť udalosti. Tento prístup môže poskytnúť príležitosti pre ziskové stávky aj pri nižšej celkovej presnosti predikcií.

Z týchto dôvodov sa presnosť sama o sebe môže javiť ako nedostatočná metrika pre hodnotenie a porovnávanie predikčných modelov v športovom stávkovaní. Často je nevyhnutné ju doplniť o ďalšie ukazovatele, ako je ROI, ktoré poskytujú ucelenejší obraz o výkonnosti modelu. V mnohých štúdiách spomenuté v tejto práci [15, 1, 21, 12], ktoré sa obmedzujú výhradne na metriku presnosti (prípadne Brier skóre 5.1.3, alebo F1 skóre [31]), tým pádom chýba dôležitá informácia, ktorá by umožnila plnohodnotné porovnanie efektivity rôznych prístupov.


2.3.3 Modelovanie prostredníctvom pravdepodobnostného rozdelenia

Pri predikcii futbalových udalostí sa často spolieha na štatistické modely, ktoré umožňujú pochopenie a predpovedanie rôznych aspektov hry. Jedným z prvých ale stále široko používaných prístupov, je využitie Poissonovho rozdelenia [19]. Prvým prelomovým objavom, ktorý bol urobený v oblasti predikcie futbalových zápasov, bol príspevok Mahera [22] v roku 1982. V jeho práci boli Poissonove rozdelenia použité na modelovanie útočných a obranných schopností domáceho a hosťujúceho tímu a aplikované na predpovedanie priemerného počtu gólov pre každé mužstvo. Následne Dixon a Coles [6] v roku 1997 ako prví vyvinuli model schopný vyprodukovať pravdepodobností pre výsledky zápasov a skóre, opierajúc

¹ROI - Return of Investment

sa opäť o Poissonove rozdelenie. Toto rozdelenie je založené na predpoklade, že počet gólov v zápase môže byť modelovaný ako Poissonov proces [19] (viz. graf 2.3).

Použitie tohto rozdelenia v predikcii futbalových udalostí, najmä v porovnaní s klasifikačnými prístupmi, má niekoľko výhod. Poissonovo rozdelenie je matematicky relatívne jednoduché a dobre pochopiteľné. Tento prístup poskytuje transparentnú a intuitívnu metódu pre modelovanie počtu gólov, čo je dôležité pre analýzu a interpretáciu výsledkov. Tento prístup umožňuje s použitím jediného modelu predikovať rôzne typy výsledkov, ako sú napríklad celkový počet gólov v zápase a súčasne ak vieme predikovať počet gólov v zápase pre jednotlivé tímy tak vieme odvodiť aj výsledok zápasu, alebo to či obaja dajú gól. Toto je veľká výhoda, pretože redukuje potrebu vytvárať a udržiavať viacero špecializovaných modelov pre rôzne predikcie.



Obrázok 2.3: Poissonova distribúcia počtu gólov na zápas. Tento graf zobrazuje pravdepodobnosť výskytu rôzneho počtu gólov (od 0 do 10) v jednom zápase. Hodnota λ je nastavená na priemerný počet gólov na zápas, vypočítaný z dát za posledných 12 rokov zo siedmich najlepších futbalových líg sveta. Parameter λ reprezentuje priemerný počet udalostí (gólov) na jednotku času (zápas). Červené bodky reprezentujú pravdepodobnosti jednotlivých počtov gólov.

Avšak tento prístup má svoje obmedzenia, preto v modernom modelovaní sú čoraz viac uprednostňované klasifikačné prístupy. Klasifikačné modely, ako sú Random Forest, Support Vector Machine (SVM), alebo neurónové siete, poskytujú väčšiu flexibilitu v modelovaní zložitých vzorcov a interakcií medzi rôznymi premennými. Napríklad, sú schopné lepšie zohľadniť taktické zmeny, formácie tímov, alebo dokonca psychologické faktory hráčov, čo je niečo, čo Poissonov model môže len ťažko zachytiť.

V štúdiách [17, 34, 28, 6], kde bol využitý Poissonov model, bola zaznamenaná rôzna presnosť pri predikovaní futbalových udalostí. Sústredil som sa na predpovedanie troch špecifických futbalových udalostí: či oba tímy dajú gól, čo označujem ako (ODG), výsledok zápasu, označovaný ako (VYS), a či bude celkový počet gólov viac (alebo menej) ako 2.5, čo označujem ako (V/M 2.5). Použitím modelu založeného na Double Poisson distribúcií [32]

sa dosiahli najlepšie výsledky pri predikcii všetkých troch typov udalostí. Najvyššia presnosť 56,55% bola zaznamenaná pri predpovediach počtu gólov. Pri predikcii, či oba tímy dajú gól, bola presnosť 53,89% a pri určovaní výsledku zápasu sa dosiahla presnosť 51,19%. Tieto výsledky sú zhrnuté v tabuľke 2.1.

Model	Typ výstupu	Udalosť	Presnosť	ROI	Štúdia
Neurónová sieť	Double poisson rozdelenie	V/M 2.5	56.55%	-7.1%	[34]
Neurónová sieť		ODG	53.89%	-6.8%	[34]
Neurónová sieť		VYS	50.78%	-7.2%	[34]

Tabuľka 2.1: Tabuľka poskytuje súhrn najúspešnejších modelov založených na Poissonovej distribúcii, podľa existujúcich štúdií s dôrazom na presnosť modelov a ich návratnosť investícií (ROI) (viz. sekcia 5.1.2). Koncept *Double Poisson* predstavuje prístup, pri ktorom autori najprv odhadujú parametre tejto distribúcie pomocou neurónovej siete, ktoré potom používajú na predikciu výsledkov jednotlivých zápasov.

2.3.4 Modelovanie prostredníctvom klasifikácie

Tento prístup predstavuje významný odklon. Nehovorí sa tu o žiadnych predpokladoch ohľadne distribúcie. Vo svete klasifikácie sú na výber rôzne triedy. V tomto prípade ide o udalosti, ktoré sa snažím predpovedať. Tréningová sada je zostavená zo vstupných príznakov a príslušných označení (ground truth), napríklad udalosť „počet gólov viac ako 2.5“ môže byť označená ako pravdivá, alebo nepravdivá. Modely neponúkajú špecifikované pravdepodobnosti pre jednotlivé skóre, avšak poskytujú pravdepodobnosti pre každú z tried.

Hlavnou nevýhodou tohto prístupu je, že ak chceme pre jednoduchosť zachovať binárnu klasifikáciu tak pre každý typ udalosti sa vyžaduje nový model, čo môže byť výpočetne náročné, ak máme v úmysle predpovedať viaceré udalosti. Príkladom je predpoveď viacero udalostí počtu gólov, kde ak chceme určiť, či ich bude viac ako $\mathbf{X}$ (napríklad viac ako 1.5, viac ako 2.5 atď.), je potrebné za každým vypracovať nový model pre pravdepodobnosť $P(g > x)$ kde $x \in \mathbf{X}$.

Na druhej strane, tento prístup ponúka jednoduchosť a lepšiu interpretovateľnosť. Dokáže efektívne spracovať a škálovať veľké dátové sady. Dokáže ľahko zvládnuť kategorické premenné. Dokáže modelovať interakcie medzi premennými a podobne.

V štúdiách [3, 12, 15, 27], kde boli použité modely strojového učenia predikujúce pravdepodobnosť triedy (alebo samotnú triedu), bola dosiahnutá vysoká úroveň presnosti a ziskovosti. Napríklad bol dosiahnutý výsledok 59.13% presnosti pri použití 4 vrstvovej umelej neurónovej siete pre udalosť „počet gólov viac ako 2.5“ (V/M 2.5). S modelom XGBoost [5] dosiahli priemernú presnosť 63.95% a profit 19.7%. Ďalej, neurónová sieť dosiahla 68.8% úspešnosť pri predikovaní udalosti „výsledok zápasu“ (VYS). Je však potrebné podotknúť, že predikcie boli realizované len pre skupinovú fázu Ligy majstrov, ktorá zahŕňa 96 zápasov, čo by mohlo viesť k určitému skresleniu výsledkov. Na druhej strane, v ďalšej štúdii bola pri použití metódy SVM [18] dosiahnutá presnosť 61.32%, pričom testy boli vykonané na 360 zápasoch.

Model	Typ výstupu	Udalosť	Presnosť	ROI	Štúdia
Neurónová sieť	Pravdepodobnosť triedy	V/M 2.5	59.13%	16,54%	[3]
Neurónová sieť		VYS	68.8%	-	[15]
XGBoost		VYS	63.95%	19.7%	[27]
SVM		VYS	61.32%	12.5%	[18]
Random Forest		VYS	59.21%	11.11%	[27]

Tabuľka 2.2: Tabuľka prezentuje súhrn najúčinnějších klasifikačných modelov podľa rôznych vedeckých prác s ohľadom na presnosť modelov a ROI (viz. sekcia 5.1.2). Z analýzy štúdií, ktoré sa zaoberali klasifikačnými modelmi, nebola udalosť „obaja dajú gól“ (ODG) explicitne skúmaná, a preto nie je zahrnutá v prehľade uvedenom v tejto tabuľke.

2.3.5 Analýza sociálnych sietí a ich význam pre predikciu futbalových výsledkov

V práci Frederica Godina [11] je preskúmaný potenciál využitia informácií získaných z Twitteru, konkrétne viac než 50 miliónov postov, pre predikciu výsledkov futbalových zápasov. Twitter sa ukázal ako bohatý zdroj kolektívnej inteligencie, poskytujúci unikátny uhol pohľadu na verejnú náladu, pocity voči tímom a dokonca aj konkrétne predpovede skóre od užívateľov. Využitím postov autori vytvorili tri metódy na extrakciu a agregáciu dát z Twitteru.

- **Analýza objemu Twitteru:** Metóda založená na objeme tweetov, kde vyšší počet tweetov pred zápasom môže indikovať väčšiu podporu alebo záujem o daný tím.
- **Analýza citlivosti:** Využitie vlastného klasifikátora na určenie citlivosti tweetov. Tweety boli klasifikované ako pozitívne, negatívne alebo neutrálne, a to na základe obsahu a kontextu, čo poskytovalo prehľad o názoroch fanúšikov.
- **Analýza predikcií užívateľov:** Agregácia a analýza predpovedí skóre uvedených užívateľmi v ich tweetoch. Táto metóda vypočítavala priemerné predpovedané skóre založené na užívateľských tweetoch, čo poskytovalo ďalšiu perspektívu na očakávaný výsledok.

Vďaka kombinácii tradičných štatistických metód a inovatívneho využitia dát zo sociálnych médií dokázali autori nielen predpovedať výsledky s vysokou presnosťou (najlepší model dosahoval až 70%), ale aj teoreticky dosiahnuť významný zisk pri stávkovaní na futbalové zápasy (V práci sa uvádza takmer 30%). Táto práca ilustruje potenciál kombinácie viacerých zdrojov dát a pokročilých analytických techník v športovej analytike.

Integrácia veľkých jazykových modelov (LLM²), otvára príležitosť pre ešte hlbšie spracovanie a pochopenie obsahu zo sociálnych sietí. LLM môžu pomôcť pri spracovaní poznatkov z rôznych tweetov do kvalitnejšieho zhodnotenia predpovedaného výsledku.

2.4 Analýza použitých predikčných modelov

V predchádzajúcej časti bolo vykonané porovnanie najčastejšie využívaných prístupov k modelovaniu pri predikcii futbalových udalostí, konkrétne modelov založených na pravdepodobnostnom rozdelení a klasifikačných modelov. Z analýzy vyplynulo, že klasifikačné modely

²LLM - Large Language Model

vo väčšine situácií ukázali lepšiu odolnosť voči náhodným javom a predčili modely založené na pravdepodobnostom rozdelení z hľadiska presnosti predikcií. V tejto sekcii budú prezentované tie najpoužívanejšie klasifikačné modely aplikované na danú problematiku, ako aj niektoré inovatívne prístupy, ktoré vynikli svojou originalitou a demonštrovali pomerne solídne výsledky.

Hucaljuk a Rakipović [15] testovali modely Random Forest, Bayessovu sieť, Logit Boost a metódu K-Najbližších Susedov. V tejto štúdií autori dosiahli presnosť nad 53% pri všetkých modeloch, pričom niektoré z nich dosiahli dokonca presnosť vyššiu ako 60%. Avšak je dôležité ešte raz poznamenať, že tieto modely boli testované iba na skupinovej fáze Ligy majstrov, čo predstavuje len 96 zápasov. Autori si vytvorili dve skupiny príznakov - "základné" a "expertné" ako to je v tabuľke 2.3. Zaujímavým zistením bolo, že väčšina modelov dosiahla vyššiu (alebo rovnakú) presnosť na základnej skupine príznakov. Tento výsledok by mohol naznačovať, že príliš detailné dáta nemusia byť úplne vhodné, ak je veľkosť datasetu extrémne malá.

Model	Príznačky	Presnosť	Príznačky	Presnosť
Neurónová sieť	Základné	68.8%	Expertné	68.8%
Bayessovská sieť		56.3%		56.3%
LogitBoost		62.5%		68.8%
Nahodný les		65.6%		53.1%
Metóda najbližších susedov		62.5%		56.3%

Tabuľka 2.3: Tabuľka sumarizuje výsledky presnosti rôznych klasifikačných modelov testovaných v skupinovej fáze Ligy majstrov podľa štúdie Hucaljuka a Rakipovića [15]. Modely boli hodnotené s dvoma typmi príznakov - základnými a expertnými. Väčšina modelov vykazovala vyššiu alebo rovnakú úroveň presnosti pri základných príznakoch, čo naznačuje možnú obmedzenú účinnosť komplexných príznakov v obmedzených dátových súboroch.

V štúdiu Herbinet [12] bolo pri vytváraní všeobecného modelu klasifikácie, predpovedajúceho výsledok hry na základe hodnotenia Elo (viz. sekcia 2.5.1), testovaných osem rôznych modelov. Model SVM s lineárnou funkciou jadra preukázal najlepšiu presnosť. Autori ďalej použili prístup postupného predikovania, kde bol najprv vytvorený **model pravdepodobnosti útočných akcií, ktoré mohli skončiť gólom**, potom bolo predikované **množstvo gólov v zápase**, následne bolo vypočítané hodnotenie **Elo jednotlivých tímov** a nakoniec boli natrénované klasifikačné **modely, ktoré sa snažili predikovať výsledok zápasu**.

V práci Hubáček [13] využil modely neurónových sietí, pričom sa zdôraznila dôležitosť **dekorelácie od kurzov stávkových kancelárií** ako kľúčového faktora pre dosiahnutie ziskovosti. Tento prístup zahŕňa vyváženie kompromisu medzi presnosťou predikcií a dekoreláciou od kurzov stávkových kancelárií pomocou upravenej objektívnej funkcie (viz. sekcia 2.5.4). Autor v práci zistil, že takýto prístup je efektívny a vedie k pozitívnym výnosom.

Rodrigues a Pinto [27] použili XGBoost, Random Forest a SVM, pri ktorých bolo dosiahnuté, že vo všetkých prípadoch presnosť prekročila 62%. Autori aplikovali iba základné príznaky, ako **priemerný počet gólov za posledných 5 zápasov**, **držanie lopty**, **strely na bránu**, **kurzy od stávkových kancelárií** a **hodnotenie výkonnosti obrany, stredovej línie a útoku**. Bolo dosiahnuté pomerne vysokej návratnosti investície až 26%. Zaujímavé je, že takáto vysoká ziskovosť bola dosiahnutá aj pri použití kurzov stávkových kancelárií ako jedného z príznakov. Použitím kurzov stávkových kancelárií bolo naznačené, že predpovede by mohli korelovať s predpoveďami stávkovej kancelárie. Tento fakt by zvyčajne nemal priniesť zisk,


keďže kurzy od stávkovej kancelárie sú nastavené tak, aby boli pre hráča neférové (viz. sekcia 2.5.4). Preto tento prístup bude podrobený experimentom.

Pri športovom stávkovaní je schopnosť modelu odchyľovať sa od predpovedí bookmakerov rovnako dôležitá ako jeho predikčná presnosť. Optimalizáciou oboch aspektov môže model identifikovať hodnotné stávky, ktoré sú na trhu prehliadané alebo podhodnotené. Pravdepodobne vedie tento prístup k ziskovejším stávkovým príležitostiam aj za cenu menšej presnosti, využívajúc neefektívnosť na trhu športových stávk. Táto neefektívnosť vzniká z prílišného spoliehania sa na kurzy stávkových kancelárií. V praxi to znamená, že sú identifikované udalosti, ktoré sú stávkovou kanceláriou nadhodnotené.

V nasledujúcich podsekcích budú rozoberané konkrétne modely, ich prednosti, slabiny a oblasti aplikácie v kontexte predikcie futbalových udalostí.

2.4.1 Analýza a aplikácia modelu Random Forest

Random Forest (RF) vytvára počas tréningu súbor rozhodovacích stromov, kde každý strom je trénovaný na náhodne vybranej podmnožine dát pomocou baggingu. Tento proces zahŕňa vytvorenie Bootstrap vzorky s možnosťou opakovaného výberu prvku. Nezávisle trénované modely na týchto vzorkách potom využívajú väčšinové hlasovanie na určenie výsledku, pričom výsledky z jednotlivých modelov sa kombinujú do konečného výstupu prostredníctvom agregácie, čo zlepšuje presnosť predpovedí.




Obrázok 2.4: Schéma algoritmu Random Forest zobrazujúce kolektívne rozhodovanie viacerých rozhodovacích stromov. Každý strom dostáva novú vzorku dát a nezávisle na ostatných produkuje predikciu výsledku. Výsledné hlasovanie alebo priemerovanie týchto predikcií vedie k finálnej predikcii modelu. Tento proces znižuje variáciu a predchádza pretrénovaniu, typické pre jednotlivé rozhodovacie stromy.

Pri použití Random Forest pre časovo závislé dáta, ako sú napríklad futbalové dáta, je potrebné venovať pozornosť. Tento algoritmus, rovnako ako mnohé iné algoritmy strojového učenia, predpokladá nezávislosť medzi jednotlivými pozorovaniami. Tento predpoklad môže byť problematický v prípade dát časových radov, kde je dôležitá postupnosť udalostí a ich načasovanie. Preto sa odporúča využiť príznaky založené na čase, ktoré zachytávajú časové aspekty dát. Tieto môžu zahŕňať dátum zápasu, herné kolo, alebo čas uplynulý od poslednej hry. Vďaka mechanizmu náhodného výberu prvkov a stromov, Random Forest lepšie generalizuje a je menej náchylný k preučeniu a tak isto výborne zvláda dáta s veľkým počtom príznakov.

2.4.2 Analýza a aplikácia modelu XGBoost

XGBoost, skratka pre eXtreme Gradient Boosting, je v oblasti strojového učenia uznaná ako pokročilá implementácia algoritmu gradient boosting [25]. Tento algoritmus je účinný pri analýze futbalových dát, predovšetkým vďaka svojej vysokej schopnosti vysporiadať sa s veľkým počtom príznakov. XGBoost vytvára konečné predpovede kombinovaním výsledkov z viacerých rozhodovacích stromov. Jeho regularizačná zložka zabraňuje preučeniu a zlepšuje celkovú výkonnosť. XGBoost dokáže automaticky spracovávať chýbajúce hodnoty, čo je výhodou pri práci s reálnymi dátami. Na rozdiel od tradičných metód gradient boostingu, ktoré zastavujú rozdeľovanie uzlov pri dosiahnutí určitej podmienky, XGBoost rozdeľuje uzly do maximálne nastavenej hĺbky a potom začína proces orezávania, čo umožňuje hlbšiu a detailnejšiu analýzu dát. Jeho nevýhodou je väčšia výpočetná náročnosť.



Obrázok 2.5: Sekvenca krokov ilustrujúca tréning XGBoost klasifikátora. Proces začína s trénovacím datasetom, kde každý z troch postupných klasifikátorov sa učí na vstupných dátach, pričom každý nasledujúci klasifikátor sa zameriava na nápravu chýb predchádzajúcich. Oblasť, kde každý klasifikátor zasahuje, je zobrazovaná s hraničnými čiarami ukazujúcimi prahové hodnoty (m , n , p), ktoré rozdeľujú priestor na regióny rozhodnutia. Finálny klasifikátor potom kombinuje výstupy všetkých predchádzajúcich stromov do jedného rozhodnutia, čo ilustruje model v poslednom paneli, kde sú rôzne regióny farebne odlíšené podľa výslednej klasifikácie.

XGBoost postupne pridáva modely do súboru, pričom každý nový model sa snaží napraviť chyby predchádzajúceho modelu. Rozhodovacie stromy sú tvorené tak, aby sa sústredili na predpovedanie reziduí z predchádzajúcich stromov. Objektívna funkcia XGBoostu je určená nasledujúcou rovnicou:

$$L(\phi) = \sum_i l(\hat{y}_i, y_i) + \sum_k \Omega(f_k) \quad (2.1)$$

$$\Omega(f) = \gamma T + \frac{1}{2} \lambda \|w\|^2 \quad (2.2)$$

kde celková loss funkcia modelu, označená ako $L(\phi)$, určená kombináciou dvoch hlavných prvkov: loss funkcie a regularizačného faktora. Loss funkcia, vyjadrená ako $l(\hat{y}_i, y_i)$, poskytuje meranie chyby medzi predpovedanou $\hat{y}_i$ a skutočnou hodnotou y_i pre každý prípad i . Na druhej strane, regularizačný faktor $\Omega(f_k)$ (funkcia f_k predstavuje jednotlivé stromy), pridáva penalizáciu za komplexnosť modelu, kde γT zohľadňuje počet koncových uzlov T s penalizáciou γ , a $\frac{1}{2} \lambda \|w\|^2$ penalizuje veľkosť váh w v koncových uzloch, s λ ako regularizačným koeficientom. Tieto elementy spoločne zaisťujú, že model dosahuje dobrú rovnováhu medzi presnosťou a schopnosťou generalizácie, čím znižujú riziko preučenia.

2.4.3 Analýza a aplikácia modelu neurónová sieť

Neurónové siete, známe tiež ako umelé neurónové siete (ANN), predstavujú systémy založené na súbore uzlov (neurónov), ktoré na algoritmickej úrovni napodobňujú vzťahy medzi neurónmi v ľudskom mozgu. Každý neurón v týchto sieťach je schopný prijímať signály od iných neurónov a odovzdávať ich ďalším neurónom. Neuróny sú spojené hranami, ktorým sú priradené váhy. Tieto váhy modelujú dôležitosť vstupu jednotlivých neurónov pre výstup ďalších neurónov.

Každá neurónová sieť sa zvyčajne skladá z viacerých vrstiev: vstupnej vrstvy, kde každý neurón reprezentuje jednu vstupnú premennú modelu, výstupnej vrstvy, ktorá poskytuje výsledok klasifikácie (alebo regresie), a jednej alebo viacerých skrytých vrstiev, ktoré sa nachádzajú medzi vstupnou a výstupnou vrstvou. Počet neurónov v každej skrytej vrstve môže byť rôzny. Obrázok 2.6 ilustruje architektúru neurónovej siete s jednou skrytou vrstvou.

V neurónovej sieti každý neurón spracováva vstupy x_i s váhami $w_{i,j}$ a poskytuje výstup h_j . Aktivačná funkcia pre neurón v skrytej vrstve je reprezentovaná ako:

$$h_j = f\left(\sum_i w_{i,j} \cdot x_i + \text{Bias}_j\right) \quad (2.3)$$


kde f je aktivačná funkcia, $w_{i,j}$ je váha priradená spojeniam medzi vstupom i a skrytým neurón j , a Bias_j je posun, teda bias pre j -tý neurón.

Pri tréningu neurónovej siete je proces aktualizácie váh založený na algoritme spätného šírenia chyby, pri ktorom sú váhy $w_{i,j}$ a biasy upravované s cieľom minimalizovať chybu predikcie. Aktualizácia váh sa vykonáva podľa gradientu loss funkcie, ako je uvedené v nasledujúcom vzorci:

$$w_{i,j}^{(t+1)} = w_{i,j}^{(t)} - \eta \frac{\partial \mathcal{L}}{\partial w_{i,j}} \quad (2.4)$$

$$\text{Bias}_j^{(t+1)} = \text{Bias}_j^{(t)} - \eta \frac{\partial \mathcal{L}}{\partial \text{Bias}_j} \quad (2.5)$$

kde η je miera učenia, ktorá určuje veľkosť kroku aktualizácie, $\mathcal{L}$ je loss funkcia a t označuje aktuálny krok tréningu.



Obrázok 2.6: Grafická reprezentácia umelej neurónovej siete s jednou skrytou vrstvou.

Výhody používania neurónových sietí ako klasifikačných modelov spočívajú v tom, že tieto modely zvyčajne dosahujú vysokú úroveň presnosti predikcie v porovnaní s inými technikami. Avšak, na optimalizáciu modelu sa vyžaduje veľké množstvo tréningových dát. Je tiež potrebné mať na pamäti, že neurónové siete nemusia konvergovať k jednotnému riešeniu a nie sú deterministické. Ďalej, neurónové siete nie sú ľahko interpretovateľné, pretože obvykle obsahujú príliš veľa vrstiev a neurónov, čo sťažuje pochopenie smeru a veľkosti asociácie medzi každou vstupnou a výstupnou premennou. Bez adekvátnej regularizácie alebo pri nadmernom počte parametrov sa môžu ľahko pretrénovať. Často sú považované za „čierne skrinky“, čo znamená, že ich predpovede môžu byť ťažko interpretovateľné. Proces tréningovania môže byť tiež výpočtovo a časovo náročný, najmä pri hlbokých sieťach, a zvyčajne vyžaduje veľké množstvo dát na efektívne tréningovanie.

Neurónové siete môžu byť mimoriadne účinné pri predikcii futbalových udalostí z viacerých dôvodov. Futbalové dáta sú multidimenzionálne a obsahujú rôzne faktory ako štatistiky hráčov, tímové výkony a historické výsledky. Tieto siete sú schopné spracovať a analyzovať tieto komplexné a prepojené dáta, čím umožňujú objavovať vzorce a súvislosti, ktoré by inak mohli zostať nepovšimnuté. Neurónové siete sú prispôsobiteľné na široké spektrum predikčných úloh vo futbale, vrátane predpovedí výsledkov zápasov, hodnotenia výkonnosti hráčov alebo identifikácie kľúčových herných momentov. Neurónové siete sú tiež efektívne pri modelovaní a predpovedaní dát, ktoré majú časový aspekt, ako napríklad forma tímu a vývoj herných štýlov. Sú schopné učiť sa a integrovať informácie z rôznych oblastí, vrátane psychológie hráčov, taktiky hry a meteorologických podmienok, čo všetko môže ovplyvniť výsledok futbalového zápasu.


Neurónová sieť sa široko používa v oblasti predikcie futbalových udalostí a môže byť považovaný za jeden z najčastejšie používaných. Tento záver je podporený množstvom relevantných štúdií, na ktoré som pri analýze narazil [1, 33, 21, 12].

V tejto práci sa používa neurónová sieť na „high-level“ úrovni bez potreby detailného rozboru jej komplexných mechanizmov. Zameriavam sa na základné aspekty: definíciu vstupov, architektúru siete, primeraný počet príznakov a výstupy siete.

2.4.4 Analýza a aplikácia modelu neurónová sieť s konvolučnými vrstvami

Prístup použitý Hubáčkom [13] se zdá byť nekonvenčný, pretože využíva konvolučné vrstvy, ktoré ako vstupy berú matice zložené z hráčov a ich štatistík. Tento inovatívny prístup prináša dve hlavné novinky: dekoreláciu od modelu stávkovej kancelárie a využitie konvolučných neurónových sietí na predpovedanie výsledkov futbalových zápasov. Na vstupe konvolučnej vrstvy neurónovej siete sa spracováva obrovské množstvo štatistických dát o hráčoch.

Model využíva konvolučnú vrstvu, za ktorou nasledujú tri plne prepojené vrstvy. Táto konvolučná sieť je špeciálne navrhnutá tak, aby zvládla spracovanie veľkého počtu relevantných príznakov na úrovni hráčov. Princíp jej fungovania, inšpirovaný aplikáciami konvolučných sietí v oblasti spracovania vizuálnych údajov a je ilustrovaný na obrázku 2.7. Konvolučná vrstva môže byť intuitívne chápaná ako most, ktorý transformuje premenné na úrovni hráčov do reprezentácie na úrovni tímu. Na rozdiel od premenných na úrovni tímu, ktoré sú v dátach zahrnuté ako jednoduché súčty alebo priemery za všetkých hráčov tímu, konvolučná vrstva umožňuje vytvoriť komplexnejší vzor agregácie, ktorý sa učí priamo z tréningových údajov. Architektúra tejto siete je nasledovná:



Obrázok 2.7: Architektúra neurónovej siete s konvolučnými vrstvami. Konvolučné vrstvy transformujú štatistiky hráčov (príklad vstupu štatistík hráčov v sekcii 4.1) do jednorozmerného vektora, ktorý sa následne môže použiť so štatistikami na úrovni tímu.

Vstupom do siete sú dve matice (jedna pre domáci tím, jedna pre hostí), s hráčmi v riadkoch a všetkými príznakmi na úrovni hráčov v stĺpcoch. Je potrebné zahrnúť niekoľko najlepších hráčov. Výstupom vrstvy je vektor, kde každá zložka je bodovým súčinom predchádzajúceho vektora s jedným z maticových stĺpcov. Vektor je možné vidieť ako filter posúvajúci sa horizontálne na prvej vstupnej matici a potom na druhej.

S využitím tohto prístupu dosiahol Hubáček [13] sľubné výsledky, a to s priemernou presnosťou 67.2% a profitom 1.79%. Tieto výsledky naznačujú, že aplikovaná metóda poskytuje robustnú a efektívnu stratégiu pre predikciu futbalových udalostí.

2.5 Analýza príznakov

Táto sekcia sa zameriava na rozbor príznakov, ktoré boli v dostupných štúdiách vybrané pre tréning modelov. Hoci to tak na prvý pohľad nemusí vyzerať, futbal je šport s vysokou mierou komplexnosti, pokiaľ ide o faktory, ktoré môžu ovplyvniť priebeh hry. Relevanciu majú napríklad **individuálne štatistiky hráčov**, **ofenzívne a defenzívne schopnosti tímu**, ale aj zápasové štatistiky ako **priemerný počet striel, gólov, prihrávk, centrov**, atď. Existujú aj ďalšie aspekty, ktoré môžu hru ovplyvniť, ako **aktuálne umiestnenie tímov v tabuľke** (napríklad tím, ktorý má už istú pozíciu, môže hrať odlišným štýlom, keďže pre nich už hra nemá väčší význam), **forma tímu**, **meteorologické podmienky**, **vyťaženosť**, **zranenia**, **vedenie trénera**, a mnohé ďalšie. Prítomnosť ľudského faktora pridáva hre mnoho premenných, ktoré môžu mať vplyv na konečný výsledok. V tejto sekcii je preto kľúčové zamerať sa na identifikáciu tých príznakov, ktoré sú najrelevantnejšie a ktoré môžu pozitívne prispieť k presnejšej predikcii.

V mnohých štúdiách [35, 7, 1, 8] boli použité základné štatistiky, ako napríklad **počet gólov obidvoch tímov, ofsajdy, žlté karty, strely na bránu a formácie**, ktoré sú dostupné **až po odohraní daného zápasu**. Preto bývajú tieto štatistiky často dopočítavané rôznymi spôsobmi, najčastejšie pomocou **kľzavého priemeru**. Hoci sú tieto štatistiky dôležité pre predikciu, nie sú samy osebe dostatočné pre dosiahnutie výkonného predikčného systému.

Niektoré ďalšie práce [33, 23] sa snažili odvodiť z týchto základných príznakov nové charakteristiky, ako je napríklad počet výhier alebo prehíer v rade, akumulovaný počet bodov tímu počas sezóny, priemerný rozdiel počtu gólov za sezónu v zápasoch doma a vonku. Ďalšie štúdie išli ešte ďalej a odvodili nové príznaky, ktoré boli vytvorené rôznymi prístupmi založenými na logickom usudzovaní, ktoré v nasledujúcich podkapitolách predstavím.

2.5.1 Systém hodnotenia Elo

Systém hodnotenia Elo [16] bol vyvinutý maďarsko-americkým fyzikom a šachovým majstrom Arpadom Elo. Tento systém vyvinul na zlepšenie hodnotiaceho systému šachových hráčov, ale bol široko prijatý v rôznych iných športoch vrátane futbalu. Hlavným cieľom používania hodnotenia Elo je zachytiť **výkonnosť tímu v priebehu času** a prispôbiť stratégiu počas zápasov. Hodnotenie Elo sa **prepočítava po každom zápase**, čo umožňuje priebežnú aktualizáciu relatívnej sily každého tímu. Každému tímu je možné priradiť hodnotenie Elo ako meradlo aktuálnej sily tímu. Hodnotenia Elo sa prepočítavajú pomocou vzorca, ktorý zohľadňuje **skutočný výsledok zápasu** a **očakávaný výsledok zápasu**. Ak tím dosiahne lepší výsledok, ako sa očakávalo, jeho hodnotenie Elo sa zvýši a naopak. Tento vzorec vypočíta pravdepodobnosť výhry, remízy alebo prehry pre oba tímy na základe ich súčasných hodnôt Elo.

$$\gamma^D = \frac{1}{1 + c^{\left(\frac{\ell_0^V - \ell_0^D}{d}\right)}} \quad \text{a} \quad \gamma^V = 1 - \gamma^D \quad (2.6)$$

kde:

- ℓ_0^D / ℓ_0^V - je aktuálne hodnotenie Elo doma, respektíve vonku
- γ^D - je **očakávané skóre** pre domáci tím.
- c a d - sú konštanty, ktoré sa používajú na úpravu citlivosti vzorca.

1. Výpočet očakávaného skóre pro domáci tým (γ_D):

$$\gamma_D = \frac{1}{1 + 10^{\left(\frac{1600 - 1500}{400}\right)}} = \frac{1}{1 + 10^{(0.25)}} = \frac{1}{1 + 2.5} = \frac{1}{3.5} \approx 0.286$$

2. Výsledok zápasu:

Předpokládáme, že domáci tým vyhrál. Pak:

$$\alpha_D = 1$$

$$\alpha_V = 0$$

Příklad

Předpokládejme, že máme dva fotbalové týmy: tým A (domáci) a tým B (hostující). Jejich počáteční 19 hodnocení Elo jsou následující:

- $\ell_{A0} = 1500$
- $\ell_{B0} = 1600$

Dále, konstanty $c = 10$ a $d = 400$.

Předpokládejme, že $k = 32$.

$$\ell_{A1} = 1500 + 32(1 - 0.286) = 1500 + 32 \times 0.714 = 1500 + 22.848 \approx 1523$$

$$\ell_{B1} = 1600 + 32(0 - 0.714) = 1600 - 32 \times 0.714 = 1600 - 22.848 \approx 1577$$

Po zápase má tedy tým A nové hodnocení 1523 a tým B nové hodnocení 1577.

Potom skóre pre domáci tím sa vypočíta nasledovne:

$$\alpha_D = \begin{cases} 1 & \text{Ak vyhral domáci tím} \\ 0.5 & \text{Ak bola remíza} \\ 0 & \text{Inak} \end{cases} \quad (2.7)$$

$$\alpha_V = 1 - \alpha_D$$

Hodnotenie Elo sa aktualizuje po zápase a nové hodnotenie domáceho tímu je

$$\ell_1^D = \ell_0^D + k(\alpha^D - \gamma^D) \quad (2.8)$$

- k - kvantifikuje zmenu v hodnotení tímu po jednom zápase, čím kontroluje citlivosť systému na výsledky zápasov. Vysoké k zvyšuje citlivosť, čo spôsobuje, že hodnotenia sa pri každom zápase viac menia, zatiaľ čo nízke k citlivosť znižuje, takže systém je stabilnejší, ale pomalšie odráža zmeny vo výkone tímu.
- Nové hodnotenie ℓ_1^V pre hostujúci tím sa vypočíta rovnakým spôsobom.

Určite by bolo možné hodnotenie Elo rozšíriť o možnosť jeho výpočtu pre rôzne časti tímu, ako sú obrana, záloha a útok. Toto umožňuje lepšie zachytiť hodnotenie jednotlivých tímov. Zároveň poskytuje podrobnejší pohľad na výkonnosť tímov, pretože sa zameriava nielen na celkové výsledky, ale aj na špecifické aspekty hry. V systéme hodnotenia Elo sa útočné hodnotenia interpretujú ako očakávaný počet gólov, ktoré by tím mohol streliť proti priemernému tímu. Opačne, defenzívne hodnotenia udávajú očakávaný počet gólov, ktoré by tím mohol inkasovať od priemerného tímu. Stredové hodnotenia by potom mohli predstavovať rozdiel medzi ofenzívnymi a defenzívnymi očakávanými počtami gólov, čím poskytujú celkový pohľad na potenciálny výkon tímu v zápase.

2.5.2 Systém hodnotenia PageRank

Víťazstvo nad slabším tímom nemusí byť vnímané ako tak významné ako tesné víťazstvo nad silným súperom. Na zohľadnenie tohto faktora bol využitý algoritmus PageRank, pôvodne vyvinutý na hodnotenie relevancie webových stránok. Algoritmus predpokladá, že sila tímu je odzrkadlená v jeho výsledkoch proti iným silným tímom. PageRank tímu je možné vypočítať z matice, kde stĺpce i riadky reprezentujú rôzne tímy a každá bunka vyjadruje relatívnu prevahu jedného tímu nad druhým, založenú na výsledkoch predchádzajúcich zápasov. Konkrétne, hodnota bunky i, j je definovaná ako:


$$\frac{3w_{ij} + d_{ij}}{g_{ij}} \quad (2.9)$$

kde w_{ij} a d_{ij} označujú počet víťazstiev, resp. remíz, tímu i proti tímu j , a normalizátor g_{ij} predstavuje celkový počet zápasov medzi týmito dvoma tímami. Tieto hodnoty sú získavané z aktuálnej sezóny a dvoch predchádzajúcich sezón, pričom koeficient 3 reflektuje štandardné bodovanie vo futbale [14].

2.5.3 Odhad premennej očakávaných gólov

Hlavnou myšlienkou modelu očakávaných gólov je venovať viac pozornosti výkonu na ihrisku než len konečnému skóre zápasu. Táto metóda zohľadňuje gólové príležitosti, ktoré sa


vyskytujú častejšie ako góly, a preto sú menej citlivé na vplyv vnútornej nepredvídateľnosti v konkrétnych herných momentoch. Strely sa používajú ako náhrada za gólové príležitosti, pretože sú to jasné pokusy o skórovanie a dajú sa ľahko rozpoznať. Každá strela má šancu na skórovanie v závislosti od situácie bez ohľadu na to, či vyústi do gólu. Autori [2] brali do úvahy viacero premenných vrátane pozície strely na ihrisku, spôsobu zakončenia (voľná hra, voľný kop, pokutový kop) a časti tela, ktorá bola pri strele použitá. Potom sa v priebehu jedného alebo viacerých zápasov jednotlivé pravdepodobnosti skórovania niekoľkých striel sčítajú, aby sa získala celková hodnota šance známa ako očakávaný gól (označovaná ako xG). Model očakávaných gólov bol vytvorený s cieľom vylúčiť určité nepredvídateľné prvky, ktoré by mohli skresliť výsledky zápasov, ako napríklad chyby rozhodcov, forma hráčov v deň zápasu, zranenia a počasie. Zohľadňuje oveľa viac činností ako len niekoľko skutočných gólov a kladie väčší dôraz na skutočný výkon tímu na ihrisku. Výhoda eliminácie stochastických prvkov skutočných gólov je väčšia ako nevýhoda, že sa možno stratia informácie súvisiace s kvalitami tímu, ktoré by model mohol prehliadnuť.



Obrázok 2.8: Tepelná mapa pravdepodobnosti skórovania z odpovedajúcej pozície [29]

Herbinet [12] zostavil model očakávaných gólov, ktorý berie do úvahy rôzne typy striel, ako sú klasické strely, voleje, hlavičky, voľné kopy, penalty a vlastné góly. Predpokladalo sa, že každý typ strely má inú pravdepodobnosť vedenia ku gólu, ak je vykonaný z rovnakého miesta na ihrisku. Model ďalej zohľadňuje situácie, keď tím vyhráva o jeden gól, a situácie, keď tím vedie o dva alebo viac gólov. V týchto prípadoch dochádza k úprave hodnoty očakávaných gólov, aby sa reflektovali taktické zmeny tímov v závislosti od skóre (viz. obrázok 2.9). V zápase v čase t sa začína hodnota strely lineárne znižovať až do konca zápasu, kde sa váha k pohybuje medzi 0 a 1. Tento pokles sa začína v momente, kedy sa zvyčajne vykonávajú striedania hráčov, čo je považované za indikátor taktických zmien v tíme. Ďalej sa upravuje hodnota zásahu o určitý koeficient, ak má tím na ihrisku vyšší počet hráčov kvôli červenej karte udelené súperovmu tímu. Tím s menším počtom hráčov má tendenciu podávať horší výkon, čo uľahčuje útok a skórovanie súpera.

Robborechts a Davis [26] aplikovali pre výpočet systému očakávaných gólov rôzne parametre. Tieto zahŕňali typ akcie, miesto začiatku akcie a miesto jej ukončenia. Ďalej bol zvažovaný fakt, či držal počas predchádzajúcej akcie (alebo akcií) loptu ten istý tím, ako aj smer a dĺžka posunu lopty počas týchto akcií. Uplynulý čas od predchádzajúcich akcií a uhol k bránke tiež hrali rolu v hodnotení. Hlavným cieľom modelu očakávaných gólov je vytvoriť odhady pravdepodobností akcií, ktoré mohli skončiť gólom. To znamená, že predpovedané pravdepodobnosti by mali zodpovedať očakávaným reálnym výsledkom. Napríklad, ak je



Obrázok 2.9: Graf hodnoty strely očakávaného gólu v čase, keď tím vedie. Hodnota očakávaného gólu sa znižuje, pretože vyhrávajúci tím sa má tendenciu viac brániť.

strele priradená hodnota očakávaných gólov $xG = 0.3$, teoreticky by sa očakávalo, že z 100 podobných striel by približne 30 skončilo gólom. Avšak, keďže každá strela sa vyskytuje len raz, strely s podobnými hodnotami xG sú zoskupované do košov a vypočíta sa podiel striel v každom koši, ktoré skončili gólom.

Tento prístup očakávaných gólov je vhodnejší ako reálny počet gólov v analýze futbalu, pretože znižuje vplyv náhody na hodnotenie výkonu tímov a hráčov.

2.5.4 Stávkové kurzy

Skiera, Spann [30] a Forrest, Goddard, Simmons [9] poukazujú na to, že kurzy stávkových kancelárií sú efektívnym prediktorom výsledku zápasu a prekonávajú predpovede expertov. Vzniká však otázka, či to tak naozaj je. Aj keď kurzy poskytujú významné informácie, ich začlenenie do modelu zvyšuje nežiadúcu koreláciu s bookmakerom, pretože stávkové kancelárie často nepracujú s tzv. „férovou stávkou“ (viz. sekcia 2.5.4).

Podľa mojej hypotézy, keď sa model stávkujúceho zhoduje s modelom bookmakera, vzniká paradox: stávky môžu byť sľubné z hľadiska vysokých odhadovaných pravdepodobností, ale kurz stanovený bookmakerom býva nižší ako reálna pravdepodobnosť výsledku. Tento jav robí aj veľmi presné predikčné modely neefektívnymi, ak sú príliš korelované s modelom bookmakera. Dôležitá je teda nielen presnosť na empirických dátach, ale aj nízka korelácia s modelom bookmakera.

Marža stávkovej kancelárie

Marža v stávkových kanceláriách je rozdiel medzi skutočnou pravdepodobnosťou udalosti a pravdepodobnosťou, ktorú ponúka stávková kancelária. Ak je skutočná pravdepodobnosť p , stávková kancelária môže ponúknuť pravdepodobnosť q , kde $q < p$. Toto vytvára maržu $m = p - q$, ktorá je ziskom stávkovej kancelárie. Tento rozdiel znamená, že v dlhodobom horizonte stávkujúci vyhráva menej, než by mali podľa skutočných pravdepodobností, čím sú stávky pre stávkujúcich menej výhodné.

Techniky dekorelácie v predikčných modeloch

Autori [13] skúmali modely, ktoré zahŕňajú kurzy ako príznak, alebo sú inak korelované s modelmi bookmakera. Navrhli dve techniky na zníženie nežiaducej korelácie. Prvou je technika váhovania vzoriek, ktorá ovplyvňuje výpočet chyby tréningu. Táto metóda môže

- **Zápas 3:** Skutečný výsledek $y_3 = 1$ (domáci tím vyhral), predikovaná pravdepodobnosť $p_3 = 0.7$, kurz $o_3 = 1.8$

Zápas 3:

- Klasická časť loss funkcie: $(p_3 - y_3)^2 = (0.7 - 1)^2 = 0.09$
- Korekčný člen: $c \cdot \left(p_3 - \frac{1}{o_3}\right)^2 = 0.5 \cdot \left(0.7 - \frac{1}{1.8}\right)^2 = 0.5 \cdot (0.7 - 0.5556)^2 = 0.5 \cdot 0.0208 = 0.0104$
- Celková loss funkcie pro Zápas 3: $0.09 + 0.0104 = 0.0796$

Celková loss funkcie

$$L = 0.1578 + 0.155 + 0.0796 = 0.3924$$

Tento príklad ukazuje, jak korekční člen penalizuje model za vysokou shodu s kurzy sázkových kanceláří. Zápas, kde predikovaná pravdepodobnosť p_i byla blízka hodnotě $\frac{1}{o_i}$, mají nižší nebo negativní korekční člen, což snižuje celkovou hodnotu loss funkcie. Tento přístup motivuje model, aby se méně spolehal na kurzy sázkových kanceláří a byl méně korelovaný s jejich predikcemi, což může vést k lepší efektivitě a ziskovosti modelu.

byť chápaná ako vytvorenie viacnásobných kópií tréningových príkladov s váhami úmernými ich kurzom, čo zvyšuje ich vplyv na chybu tréningu. Týmto sa model zameriava na presnosť predpovedí pre výsledky, kde vyhral tím s vysokým kurzom. V druhom prístupe boli váhy nastavené na kurzy len v prípadoch, keď vyhral outsider, zatiaľ čo pre ostatné príklady boli ponechané jednotkové váhy. Tento prístup smeruje k odhaľovaniu situácií, kde bookmakeri podceňujú pravdepodobnosť výhry outsidera.

Druhou technikou, je sofistikovanejší prístup dekorelácie. Táto metóda priamo modifikuje loss funkciu používanú pri tréningu neurónových modelov. Namiesto použitia jednoduchej sumy štvorcových chýb, loss funkcia bola rozšírená nasledujúcim spôsobom:

$$L = \sum_{i=1}^N \left((\hat{p}^i - y_i)^2 - c \cdot \left(\hat{p}^i - \frac{1}{o_i} \right)^2 \right) \quad (2.10)$$

kde:

- $\hat{p}^i$ - predstavuje výstup modelu pre i -ty príklad.
- y_i - je skutočný výsledok zápasu, ktorý môže nadobúdať hodnoty z množiny 0, 1.
- o_i - sú kurzy stanovené stávkovou kanceláriou.
- c - je konštanta, určujúca relatívnu významnosť dekorelačného člena vo funkcii.
- N - počet tréningových vzorkov v batch

Hlavnou hypotézou štúdie bolo, že korelácia medzi predpoveďami výsledkov a predpoveďami stávkových kancelárií je pre stávkujúceho nepriaznivá, a že potlačenie takejto korelácie by malo viesť k modelom s vyššími ziskami. Táto hypotéza bola potvrdená v simulovaných experimentoch a podporili ju aj rozsiahle experimenty s reálnymi dátami. Ukázalo sa, že s rastúcou koreláciou medzi modelom a stávkovou kanceláriou dochádzalo k zníženiu zisku naprieč rôznymi nastaveniami. Modely tréňované s navrhnutou loss funkciou dekorelácie dosiahli vyššie zisky, aj keď mali nižšiu presnosť v porovnaní s modelmi s vyššou koreláciou, a to až do úrovne, kde sa dosahoval primeraný kompromis medzi dekoreláciou a presnosťou [13].

2.6 Výhoda domáceho tímu


V mnohých športoch bolo zistené, že tímy dosahujú lepšie výsledky, keď súťažia na domácom ihrisku. Napríklad, v posledných piatich rokoch dosiahli tímy v bejzbale 53,7% víťazstiev, v anglickom futbale 61,0%, v ľadovom hokeji 54,6% a v basketbale 61,0%. Podľa autorov [4] môže miesto súťaže (doma vs. vonku) ovplyvniť tri hlavné faktory:

- Podpora divákov
- Potreba cestovania
- Naučená znalosť prostredia

Štúdie týkajúce sa faktorov ovplyvňujúcich domácu výhodu priniesli rozporuplné zistenia. Zistilo sa, že celkový počet divákov na zápasoch nemá významný vplyv na domácu výhodu. Naopak, hustota divákov, vyjadrená ako percentuálne zaplnenie štadióna, koreluje

s domácou výhodou pozitívne. **Správanie divákov**, či už ide o bučanie alebo povzbudzovanie domáceho tímu, nemá konzistentný vplyv na výhodu domáceho tímu. Značná pozornosť bola venovaná aj potrebe cestovania hosťujúcich tímov. Výsledky naznačujú, že **cestovanie cez časové pásma** môže byť zdrojom nevýhody pre hosťujúce tímy, avšak **dĺžka cesty** v rámci jednej ligy nemá významný vplyv na výkon hosťujúcich družstiev. Faktory ako **veľkosť hracej plochy**, **stav povrchu** alebo **typ trávniku** môžu tiež prispievať k domácej výhode.

Podporujúce dôkazy naznačujú, že **psychologický stav športovcov je lepší** pri hraní na domácom ihrisku. Hráči a tréneri majú vyššiu osobnú i tímovu orientovanú dôveru pred súťažami na domácom ihrisku, pričom emócie a nálady športovcov sú v domácom prostredí pozitívnejšie. Úzkosť, napätie, hnev a zmätenosť sú pred domácimi súťažami nižšie. Hráči sa cítia zraniteľnejší pri súťažiach na cudzích ihriskách, očakávajú posmech fanúšikov súperov. Význam domácej výhody je zrejmý z nasledujúcich grafov, ktoré ilustrujú tieto výsledky



Obrázok 2.10: Graf znázorňuje percentuálny podiel výhier, remíz a prehier domácich zápasov naprieč rôznymi futbalovými ligami. Tento prehľad ilustruje, ako domáce prostredie ovplyvňuje výsledky zápasov.

Preto je **dôležité zahrnúť do modelov príznaky zohľadňujúce výhodu domáceho prostredia**, ako sú podiely víťazstiev, remíz a prehier pre domáci hrajúci tím a rovnako aj pre hosťujúci tím.

Zhrnutie

Táto kapitola sa zaoberala pozadím modelovania futbalových udalostí. V úvodnej sekcii 2.1) sa diskutovalo o kľúčových udalostiach a pravidlách futbalu. Ďalej sa venovala analýze futbalu ako predmetu predikcie a diskutuje o dôležitosti výberu správnych dát a príznakov pre tvorbu predikčných modelov.

V sekcii 2.3 sa preskúmali špecifické metódy modelovania, ako je analýza pravdepodobnostného rozdelenia pomocou Poissonovho rozdelenia, a výhody a nevýhody klasifikačných prístupov.

Sekcia 2.4 sa podrobne venuje špecifickým predikčným modelom, ako sú Random Forest, XGBoost a neurónové siete, pričom analyzuje ich vlastnosti a spôsoby aplikácie. Diskutovalo sa o dôležitosti spracovania a selekcie príznakov a ako môžu byť tieto modely použité na efektívnu predikciu.

V sekcii 2.5 bola uvedená podrobná analýza príznakov, kde diskusia zahŕňa rôzne faktory, ktoré ovplyvňujú dynamiku futbalového zápasu. Medzi tieto faktory patria štatistiky hráčov, útočné a obranné schopnosti mužstva, štatistiky zápasu, a podobne. V tejto časti sa zdôraznila dôležitosť výberu najrelevantnejších príznakov na zlepšenie predikčnej presnosti modelov. V nasledujúcej tabuľke sú zhrnuté hlavné body, ktoré by sa mali z tejto kapitoly odniesť.

Kritérium	Klasifikačný prístup	Prístup na základe Poissonovej distribúcie
Flexibilita	Poskytuje vyššiu flexibilitu pri modelovaní komplexných vzorcov a interakcií medzi premennými.	Obmedzený predpokladom nezávislosti udalostí, menej flexibilný pri zvládání komplexných vzorcov.
Prispôsobivosť	Lepšie sa prispôsobuje taktickým zmenám, formáciám tímov a psychologickým faktorom hráčov, ktoré sú v futbale kľúčové.	Ťažkosti so zapracovaním faktorov v reálnom čase ako sú taktické zmeny a psychológia hráčov.
Rozsah predpovedí	Vyžaduje si samostatné modely pre rôzne typy predpovedí (pri binárnej klasifikácii), čo môže zvýšiť komplexitu.	Schopný predpovedať širokú škálu udalostí jedným modelom, čo zvyšuje efektivitu.
Algoritmy použité v tejto práci		
XGBoost 2.4.2	Neurónová sieť 2.4.3	Random Forest 2.4.1
Dôležité príznaky a pojmy		
Elo rating	Systém hodnotenia, ktorý odhaduje schopnosti tímov a napomáha tak predpovedať výsledky zápasov (viz. sekcia 2.5.1).	
Očakávané góly	Štatistický model, ktorý predpovedá pravdepodobnosť skórovania na základe konkrétnych situácií v zápase (viz. sekcia 2.5.3).	
Výhoda domáceho tímu	Fenomén, kedy domáci tím má tendenciu dosahovať lepšie výsledky než hosťujúci (viz. sekcia 2.6).	
Dekorelácie modelu od bookmakera	Stratégia minimalizovania závislosti predpovedí modelu na kurzoch stávkových kancelárií (viz. sekcia 2.5.4).	
Presnosť a ROI	Pre komplexné hodnotenie výkonnosti modelu je kľúčové doplniť presnosť o ďalšie metriky, medzi ktoré patrí napríklad návratnosť investície (ROI). Tieto dodatočné ukazovatele poskytujú ucelenejší pohľad na efektívnosť modelu v rôznych aspektoch a pomáhajú lepšie pochopiť jeho praktickú aplikovateľnosť (viz. sekcia 2.3.2).	

Tabuľka 2.4: Základné porovnanie klasifikačných prístupov a prístupov založených na Poissonovej distribúcii, vrátane použitých stratégií a príznakov pre predpovedanie výsledkov futbalových zápasov.

Kapitola 3

Dáta

V tejto časti sa budú podrobne analyzovať zdroje dát, ich rozdelenie, čistenie a prispôbienie pre potreby tréningu a testovania modelov. Kvalita a rozsah týchto dát predstavujú kľúčové faktory ovplyvňujúce výkonnosť a presnosť modelov, a to najmä v kontexte predikcie futbalových udalostí. Dôraz bude kladený na podrobné porozumenie pôvodu, štruktúry a charakteristikám dát, čo bude predmetom diskusie v nasledujúcich sekciách.

3.1 Pôvod dát

Dáta potrebné pre túto prácu sú špecifické a nie vždy ľahko dostupné. Mnohé rozsiahle databázy futbalových dát sa sústreďujú na základné informácie, ako výsledné skóre alebo štatistiky, a sú primárne orientované na fanúšikov futbalu. Získavanie podrobných a komplexných dát pre vedecké účely sa ukázalo byť náročnou úlohou, keďže žiadny jednotný zdroj neobsahoval všetky potrebné informácie. Výber vhodných zdrojov dát preto vyžadoval čas a úsilie. Mnohé internetové portály ponúkajú podrobné štatistiky, ale väčšinou len pre hlavné ligy a obmedzené časové obdobie, čo nedostačuje na široké a hlboké analýzy.

Ako primárny zdroj dát bol vybraný web <https://www.api-football.com/>. Tento portál poskytuje nielen základné informácie o zápasoch, ale aj rozsiahle štatistiky ako strely na bránu, držanie lopty, prihrávky, ofsajdy, karty, zranenia, zostavy, stávkové kurzy a ďalšie. Využitie týchto platených dát si vyžadovalo investíciu 90 eur (30 eur mesačne na tri mesiace), ktorá pokrývala náklady na stiahnutie a následné spracovanie dát. Počet surových (nespracovaných) dát na úrovni tímu bol 30 179.

Druhým významným zdrojom dát bol web <https://sofifa.com/>, ktorý je zameraný na populárnu sériu futbalových videohier FIFA od spoločnosti Electronic Arts. V tejto hre sú futbalistom a tímom pridelené hodnotenia (na základe reálnych výkonov) odrážajúce ich kvalitu, spolu s hodnoteniami rôznych schopností, ako sú zakončenie, manévrovanie, zrýchlenie či fyzická. Tieto údaje sa ukázali byť užitočné pri hodnotení sily jednotlivých tímov a ich potenciálneho vplyvu na predikcie výsledkov zápasov. Na extrakciu dát z tohto webu bola využitá upravená verzia webového prehliadača <https://github.com/prashantghimire/sofifa-web-scrapers> [10], umožňujúca stiahnutie dát z rôznych období. FIFA pravidelne aktualizuje hodnotenia hráčov na základe ich formy a prestupov, preto bolo nevyhnutné získať hodnotenia hráčov počas celej sezóny. Dataset obsahuje údaje za posledných 12 rokov, pochádzajúce z 38 kol každej sezóny a zahŕňa štatistiky približne 18 000 hráčov. Celkovo bolo zozbieraných viac ako 8 208 000 hodnotení hráčov, čo predstavuje 456 dátových rámcov pre rôzne časové obdobia. Pre každé kolo bola vytvorená aktuálna

sada hráčov so súčasnými štatistikami. Avšak, iba hráči, ktorí sú súčasťou tímov siedmich najlepších vybratých líg, boli zahrnutí do ďalšej analýzy. Po tomto filtrovaní zostalo 2100 hráčov na jedno kolo, čo znamená, že celkový počet štatistík sa rovná $2100 \times 38 \times 12 = 975\,600$ (z toho rozdielnych „unikátnych“ hráčov je 7023). Tento rozsiahly zber dát bol zameraný na zvýšenie presnosti predpovedného modelu. Kurzy použité v tejto práci sú prevzaté z webu <https://www.api-football.com/>, ktorý poskytuje kurzy zo známych stávkových kancelárií Bet365 a Pinnacle.

V kontexte predikcie gólov nebolo efektívne vychádzať z finálneho počtu gólov ako *ground truth*, ako už bolo spomenuté v sekcii 2.5.3 o očakávaných góloch. V dôsledku toho boli identifikované dva alternatívne zdroje, ktoré poskytujú údaje o očakávaných góloch v historických zápasoch a tieto dáta boli následne použité ako *ground truth*. Tieto zdroje, <https://fbref.com/> a <https://understat.com/>, prinášajú podobné hodnoty, pričom rozdiely medzi nimi sú minimálne.

3.2 Konštrukcia dátovej sady

Zlúčenie dát z rozličných zdrojov predstavuje výzvu, keďže každý zdroj používa rozdielne identifikátory pre zápasy, tímy, a často sa líšia aj ich názvy (napríklad jeden portál môže používať celé meno tímu a na druhom sa používa len nejaká skratka). Aby bolo možné tieto dáta integrovať, je nutné prepojiť identifikátory rovnakých entít. Spájanie sa realizuje na základe približného porovnávania názvov, metódy známej ako *fuzzy vyhľadávanie reťazcov*. Pri hráčoch je možné, že hráči sa volajú rovnako, preto spájam celé meno hráča s ich dátumom narodenia aby som užšie špecifikoval vyhľadávanie. Pri fuzzy vyhľadávaní sa používa funkcia vzdialenosti na výpočet rozdielov medzi reťazcami, v tomto prípade názvami tímov alebo menami hráčov. V tejto práci sa na výpočet týchto rozdielov využíva *Levenshteinova vzdialenosť* [24], jednoduchá, no efektívna metóda v porovnávaní reťazcov. Toto meranie vzdialenosti určuje počet vložení, vymazaní alebo zámen potrebných na transformáciu jedného mena na druhé. Všetci hráči, tímy, zápasy a súťaže sú identifikované jedinečnými číslami, čo umožňuje rozlíšiť napríklad hráčov s rovnakými menami. V tomto procese sa osvedčila knižnica *FuzzyWuzzy* v jazyku Python.

Aby som zabezpečil vysokú presnosť párovania, nastavil som prah spoľahlivosti (*threshold*) na 90%. Dáta, ktoré nespĺnili túto požiadavku, som následne manuálne upravoval. Tento postup bol prakticky uskutočniteľný, pretože v celom datasete za posledných 12 rokov bolo len 7023 unikátnych hráčov, z ktorých väčšina prešla procesom bez problémov.

Presnosť párovania tímov bola 100%, čo odráža jednoduchosť úlohy vzhľadom na malý počet tímov. Presnosť párovania hráčov sa hodnotila manuálne na základe 300 náhodne vybraných, vzájomne rozdielnych vzoriek hráčov zo spárovaného datasetu. Z týchto 300 vzoriek bola len 1 nesprávne. Chybovosť sa vypočíta nasledovne:

$$\text{Chybovosť} = \frac{\text{Počet nesprávnych párov}}{\text{Celkový počet vzoriek}} = \frac{1}{300} = 3.33 \times 10^{-3} \quad (3.1)$$

Táto chybovosť, približne 0.33%, ukazuje kvalitnú úroveň presnosti v procese párovania na náhodnej podmnožine vzoriek, čo naznačuje, že chyba je v prijateľnom rozmedzí.

Na získanie lepšieho prehľadu o tom, čo dáta obsahujú, sú v tabuľke 3.1 uvedené niektoré opisné štatistiky. Je vidieť, že v súbore dát je relatívne veľa prihrávk a že v priemere 1 z 8 striel vedie ku gólu. Ďalej je vidieť, že je tu relatívne nízky počet červených kariet. Tieto popisné štatistiky sú užitočné na získanie predstavy o tom, ako často dochádza k určitým udalostiam vo futbalovom zápase.

Sezóna	Góly	Strely	Strely na bránu	Očakávané góly	Ofsajdy	Rohové kopy	Prihrávky
2012	2.93	-	-	2.93	-	-	-
2013	3.16	-	-	3.16	-	-	-
2014	2.75	-	-	2.62	-	-	-
2015	2.83	24.95	8.84	2.82	4.98	9.54	896.00
2016	2.86	25.29	9.04	2.75	4.62	9.13	895.00
2017	2.79	26.97	9.67	2.74	4.02	9.44	897.50
2018	3.18	26.53	9.48	3.09	4.01	10.05	913.47
2019	3.21	24.74	8.98	3.08	4.04	10.08	909.65
2020	3.03	23.79	8.39	2.86	3.95	9.18	935.53
2021	3.12	25.14	8.71	3.11	3.92	9.69	892.51
2022	3.17	25.49	8.87	2.89	3.78	9.71	879.77
2023	3.15	26.22	9.26	3.03	3.61	9.77	947.61

Tabuľka 3.1: Prehľad niektorých štatistík využívaných pri tréňovaní modelu, kde hodnoty sú uvádzané ako priemer na jeden zápas. Hodnoty označené znakom „-“ predstavujú chýbajúce údaje. Tieto chýbajúce údaje neboli v príslušnom roku dostupné z použitého API. Napriek tomu boli dostupné ďalšie relevantné údaje, ako góly, tímová forma či zoznamy hráčov, čo si vyžiadalo implementáciu metód pre doplnenie chýbajúcich hodnôt. Kompletný zoznam všetkých štatistík je dostupný v prílohe B.

3.3 Prehľad dátovej sady

V rámci tejto štúdie boli analyzované dáta zahŕňajúce **27 118** futbalových zápasov, obsahujúce detailné štatistiky a hodnotenia pre **975 600** hráčov (z toho rozdielnych „unikátnych“ hráčov je 7023). Celkový počet **príznakov** je 817. Je dôležité zdôrazniť, že vždy sa využíva len špecifická podmnožina týchto príznakov v závislosti od modelu a charakteru predikovanej udalosti. Súbor dát pokrýva zápasy zo **7 rôznych líg** v období rokov 2012 až 2023. Zahŕnuté sú tiež stávkové kurzy od stávkových kancelárií **Bet365** a **Pinnacle** a rozsiahle **zápasové štatistiky**, akými sú počet gólov, prihrávok, centrov a udelených kariet. Ďalej boli spracované **tabuľkové štatistiky**, ako počet bodov, počet za sebou idúcich víťazstiev, prehíer, remíz, percentuálny podiel výhier, prehíer, remíz, alebo Elo rating. Súčasťou dát je aj premenná očakávaných gólov, ktorá bola spätne dopočítaná z analýzy videa. V nasledujúcej tabuľke 3.2 sú sumarizované tieto ligy spolu s príslušnými krajinami:

Liga	Štát	Počet tímov
Premier League	Anglicko	20
Bundesliga	Nemecko	18
Ligue 1	Francúzsko	20
Serie A	Taliansko	20
Eredivisie	Holandsko	18
Primeira Liga	Portugalsko	18

Tabuľka 3.2: Prehľad počet tímov jednotlivých líg zahrnutých v analýze

3.4 Kategórie modelov podľa vstupu

Táto práca skúma užitočnosť dodatočných dát pri predpovedaní športových udalostí. Modely boli kategorizované podľa typu dát, s ktorými pracujú.

3.4.1 Jednoduchý model

Jednoduchý (Simple) model je jednou skupinou modelov, ktoré ako vstupné dáta využívajú základné štatistiky, ako sú **ID tímov**, **priemerný počet gólov na zápas**, **dátum zápasu**, **sezóna** a **liga**. Tieto informácie sú charakterizované ako „jednoduché“, keďže sú aplikované v ich nezmenenej, pôvodnej podobe bez potreby ďalších úprav. Cieľom jednoduchého modelu je ukázať aký významný vplyv majú kvalitné dodatočné príznaky pri pokročilom modeli. Tieto modely sa budú označovať ako:

- **Simple-RF** - model RandomForest (viz. sekcia 2.4.1) s jednoduchými príznakmi
- **Simple-XGB** - model XGBoost (viz. sekcia 2.4.2) s jednoduchými príznakmi
- **Simple-NNET** - model neurónovej siete (viz. sekcia 2.4.3) s jednoduchými príznakmi

3.4.2 Pokročilý model


Tieto modely, charakterizované ich relatívnou komplexnosťou, sú navrhnuté tak, aby analyzovali množstvo rozličných príznakov. Tento prístup zohľadňuje nielen základné štatistiky, ale aj pokročilejšie metriky a vzory, ktoré sa môžu prejaviť v dynamike zápasu, poskytujúc tak celistvý a komplexný pohľad na predpovedané udalosti. Model obsahuje tieto pokročilé príznaky:

- Štatistiky **domácej výhody** (percentuálne víťazstvá/prehry/remízy v sezóne)
- Kumulatívne počty **bodov**, **víťaziev**, **prehier** atď
- Dlhodobá a krátkodobá **forma** jednotlivých tímov
- Štatistiky z **head-to-head** zápasov¹
- Štatistika **očakávaných gólov** (viz. sekcia 2.5.3)
- **Elo** rating (viz. sekcia 2.5.1)

Model je takisto **obohatený o pravdepodobnostný výstup z neurónovej siete, ktorá detailne analyzuje dáta na úrovni hráčov** (viz. sekcia 4.2.2). Tento výstup je integrovaný ako doplnkové príznaky na úrovni tímu, čím poskytuje modelu hlbší vhľad do individuálnej výkonnosti hráčov a ich potenciálneho vplyvu na celkový výsledok zápasu. Tieto modely sa budú označovať:

- **Advanced-RF** - model RandomForest (viz. sekcia 2.4.1) s pokročilými príznakmi
- **Advanced-XGB** - model XGBoost (viz. sekcia 2.4.2) s pokročilými príznakmi
- **Advanced-NNET** - model neurónovej siete (viz. sekcia 2.4.3) s pokročilými príznakmi

¹Predchádzajúce zápasy medzi dvoma konkurenčnými tímami



Obrázok 3.1: Hierarchické rozdelenie modelov použitých v analýze, kde modely sú kategorizované ako základné, jednoduché a pokročilé. Každá kategória modelov je definovaná podľa typu a komplexity, pričom jednoduché a pokročilé modely sa odlišujú počtom príznačkov, ktoré využívajú.


3.5 Rozdelenie dát pri tréňovaní

Pri **tréňovaní** modelov sa upustilo od použitia tradičnej metódy krížovej validácie kvôli jej nevhodnosti pre **časovo závislé dáta**. Krížová validácia by mohla umožniť učenie modelov z dát, ktoré sú v čase za testovými vzorkami, čo nie je v praxi možné. Preto sa zvolil **retrospektívny prístup**, kde boli nové dáta z každého odohraného zápasu postupne zapracovávané do tréňovania, aby sa zachytili aktuálne informácie. Jedným z ďalších dôvodov, prečo je dôležité prijať tento prístup k tréningu, spočíva vo výraznej dynamike futbalu. Futbal sa rok čo rok vyvíja, niekedy aj prostredníctvom zmien v pravidlách, ktoré môžu mať značný vplyv na dynamiku hry. Dobrým príkladom je zavedenie systému **VAR** v roku 2019, ktoré umožnilo presnejšie preskúmanie sporných situácií s využitím videozáznamov. Táto zmena prispela k miernemu **zníženiu počtu gólov v zápase**, čo je možné vidieť na grafe 3.1, kde medzi rokmi 2018 a 2019 došlo naozaj k miernemu poklesu. V dôsledku týchto neustálych zmien je kľúčové, aby sa predikčné modely vždy prispôbili súčasným trendom a novinkám vo svete futbalu. Na vyhodnotenie modelov sa použilo **25118** vzorkov a zvyšných **2000** bolo použitých na testovanie. Počet testovacích vzorkov bol vybraný na základe zložitosti tréňovania jednotlivých modelov.

Vizualizácia použitého retrospektívneho prístupu na obrázku 3.2 ukazuje, ako sa pre hodnotenie presnosti metód strojového učenia berie do úvahy časové usporiadanie zápasov. Napríklad, pre n -tý zápas sezóny 23/24 sa ako tréňovacie dáta používajú všetky dáta zo zápasov pred ním. Rovnaký postup sa aplikuje na zápasy do konca sezóny 23/24, kde sa ako tréňovacie dáta používajú všetky zápasy odohrané pred daným dátumom. Vyhodnotenie modelov prebieha podľa nasledovných krokov:

1. Model sa natrénuje na tréňovacích dátach.
2. Testuje sa na konkrétnych zápasoch hrané v daný týždeň a skontroluje sa správnosť predpovede.
3. Aktualizuje sa súhrnná presnosť predpovedí.
4. Testované zápasy sa pridávajú k tréňovacím dátam.

5. Test sa posunie na ďalšiu dávku zápasov v datasete.
6. Ak nie sú vyčerpané všetky dáta, proces sa opakuje od prvého kroku.



Obrázok 3.2: Schéma rozdelenia dát pre tréningovanie a testovanie v príslušných fázach. V prvom kroku je týždeň X použitý na testovanie, zatiaľ čo v druhom kroku sa používa týždeň X na tréningovanie a týždeň $X + 1$ na testovanie. Tento postup zabezpečuje, že súbor dát je efektívne využitý a následne sú výsledky spojené pre výpočet presnosti a ďalších metrík.


Zhrnutie

Kapitola tri sa venuje dátam pre modely predikcií futbalových stretnutí. Detailne rozpracúva pôvod získaných dát a proces ich úpravy do finálnej podoby datasetu, pričom poskytuje prehľad o jeho štruktúre. Táto kapitola kategorizuje modely podľa ich vstupných dát a rozoberá zložitosti jednoduchých a pokročilých modelov. Cieľom je ukázať silu kvalitných príznakov v pokročilých modeloch. Venuje sa aj rozdeleniu dát počas tréningovania, pričom zdôrazňuje dôležitosť rozdelenia dát pri tréningu prediktívnych modelov.

Kapitola 4

Návrh a implementácia systému

Celková architektúra navrhovaného a implementovaného systému je znázornená na obrázku 4.1



Obrázok 4.1: Schéma celkovej architektúry systému zobrazuje dvojfázový proces spracovania dát a modelovania. V prvej fáze sa z internetu získavajú a štrukturalizujú dáta tímov a hráčov do lokálnych úložísk. Medzi týmito fázami prebieha konverzia štatistík hráčov na príznaky na úrovni tímu. Druhá fáza zahŕňa výber a optimalizáciu modelov neurónových sietí, XGBoost a Random Forest, ktoré sa používajú na predikciu a vyhodnotenie výsledkov s použitím trénovacích a testovacích dát.

Systém je navrhnutý tak, aby pracoval v **dvoch hlavných fázach**. Počas prvej fázy je kladený dôraz na získavanie dát z internetu. Je nutné implementovať rôzne skripty, ktoré spracovávajú dáta z rozličných športových webových stránok, alebo platených API. Tieto dáta zahŕňajú informácie o zápasových štatistikách, očakávaných góloch, štatistikách jednotlivých hráčov a celkových hodnoteniach tímov.

Nasleduje proces, ktorý zahŕňa elimináciu zbytočných alebo redundantných informácií s cieľom znížiť šum a zvýšiť čitateľnosť a spracovateľnosť dát. Výsledné dáta sú následne usporiadané do vhodnej štruktúry a ukladané do lokálnej databázy pre ďalšie spracovanie. Formátom pre uloženie dát je JSON, kde sú dáta hierarchicky usporiadané podľa jednotlivých lig a sezón, čo umožňuje efektívne spravovanie a prístup k nim. Následne sú z lokálnych JSON dát budované logicky členené dátové rámce (členené podľa ligy a typu príznakov) tak isto za účelom lepšej čitateľnosti, kde **každý riadok odpovedá konkrétnemu zápasu v lige**. Dátové rámce sú ukladané vo formáte **CSV**, pričom tieto dáta sú následne poskytované algoritmom strojového učenia. Tento formát umožňuje efektívne spracovanie a jednoduchú manipuláciu s dátami, čo je nevyhnutné pre presné a efektívne strojové učenie. Prepojenie medzi JSON a CSV formátmi je kľúčové kvôli obmedzeniam prístupu skriptov k internetu (predovšetkým kvôli API, ktoré je platené a vracia dáta v JSON formáte). Tento prístup umožňuje, aby pri opakovanom generovaní dát, napríklad počas vývoja, **nebolo nutné znovu stahovať dáta z internetu**, čo výrazne zrýchľuje načítanie a spracovanie dát vďaka ich dostupnosti v lokálnej databáze.

V druhej fáze procesu sú dáta ďalej využívané ako vstup pre techniky strojového učenia. Tieto techniky sú aplikované na tréningovanie prediktívneho modelu a vykonanie predpovedí budúcich výsledkov. Po dokončení tréningovania a vykonania predpovedí sú výsledky prezentované na výstupe systému. Následne sa vypočíta **ziskovosť daného modelu**.

V nasledujúcich sekciách sa predstavia všetky modely, s ktorými budú vykonávané experimenty. Zahnuté sú základné modely aj tie, ktoré boli implementované.

4.1 Základné predikčné modely

Pre základné porovnania boli vybrané dva typy modelov. Naivný model a model založený na náhodnom výbere. **Naivný model** predpovedá vždy najčastejšiu triedu v dátovej sade, vychádzajúc z apriórnej pravdepodobnosti. Oproti tomu **model založený na náhodnom výbere** generuje predpovede úplne bez zohľadnenia dát, čo simuluje úplne náhodné rozhodovanie a poskytuje základ pre porovnanie s inými sofistikovanejšími metódami.

4.2 Implementované predikčné modely

V tejto práci sa prezentujú modely **neurónových sietí**, **Random Forest** a **XGBoost**. Tieto algoritmy budú aplikované v súlade s bežnými postupmi v oblasti strojového učenia, čo zahŕňa použitie predspracovaného datasetu a optimalizáciu parametrov každého algoritmu prostredníctvom špecifických metód. Zvláštna pozornosť bude venovaná **spracovaniu štatistík hráčov pomocou konvolučných neurónových sietí**. Tento postup a jeho význam pre analýzu futbalových dát bude podrobne rozpracovaný v nasledujúcej sekcii.

4.2.1 Schéma predikčných modelov systému

V systéme boli implementované tri modely pre predikciu futbalových udalostí. Každý z týchto modelov využíva dáta z hráčskych štatistík, ktoré sú spracované konvolučnou neurónovou sieťou. Táto sieť funguje ako most medzi individuálnymi hráčskymi štatistikami a tímovými štatistikami, pričom transformuje tieto údaje do **pravdepodobností jednotlivých udalostí**.

Tým 1:

- Hráč 1: [80, 75, 70]
- Hráč 2: [85, 80, 75]
- Týmové příznaky: [1.5, 7, 1]

Tým 2:

- Hráč 1: [78, 72, 68]
- Hráč 2: [82, 77, 73]
- Týmové příznaky: [1.2, 6, 0]

1. Konvoluční vrstva pro hráče tým 1:

- Hráčské příznaky jsou zpracovány konvoluční vrstvou, která může extrahovat a kombinovat informace, například:
 - Extrahované rysy pro tým 1 by mohly být něco jako: [agregovaná síla, agregovaná rychlost, agregovaný driblík] = [82.5, 77.5, 72.5]

2. Konvoluční vrstva pro hráče tým 2:


- Podobně pro tým 2: [80, 74.5, 70.5]

3. Spojení týmových příznaků:

- Spojení všech vstupů: [82.5, 77.5, 72.5, 1.5, 7, 1, 80, 74.5, 70.5, 1.2, 6, 0]

4. Plně propojená vrstva:

- Tento vektor prochází plně propojenou vrstvou a vytváří konečnou predikci, například:
 - Pravděpodobnost výhry domácího týmu: 0.65
 - Pravděpodobnost remízy: 0.2
 - Pravděpodobnost výhry hostujícího týmu: 0.15



Obrázok 4.2: Schéma predikčných algoritmov systému, ktorá najprv spracováva detailné štatistiky o hráčoch. Výsledkom sú pravdepodobnosti predikovaných udalostí. Tieto pravdepodobnosti sú potom spájané s datasetom na úrovni tímov, čím vzniká komplexný vstupný dataset. Následne sa tento dataset využíva ako vstup do jedného z troch dostupných modelov, ktorý produkuje konečnú predikciu udalosti.

4.2.2 Spracovanie štatistík hráčov pomocou konvolúcie

Vzhľadom na rozsiahle množstvo štatistík hráčov, kde **každému z 30 hráčov v zápase** (tj. 11 hráčov plus 4 náhradníci pre každý tím, ktorí sa vybrali na základe výkonnosti) prislúcha **33 príznakov**, je výzvou **zredukovať** tieto údaje na niekoľko významných číselných príznakov bez straty dôležitých informácií. Aby sa zachovala informácia týchto údajov, používa sa matica reprezentujúca výkonnosť jednotlivých hráčov, kde riadky predstavujú konkrétnych hráčov a stĺpce príznaky, ako je ilustrované v tabuľke 4.1.

	rýchlosť	fyzická	streľba	obrana	bránenie
Hráč 1	85	81	62	72	34
Hráč 2	97	67	77	91	85
Hráč n	85	74	82	47	56
Hráč 29	97	77	67	35	97
Hráč 30	85	82	74	77	85


Tabuľka 4.1: Hráčske štatistiky, kde stĺpce predstavujú jednotlivé atribúty hráčov a riadky konkrétnych hráčov. Táto tabuľka predstavuje **vstup konvolučnej neurónovej siete**.

Tieto informácie o zostavách sú obvykle dostupné pred začiatkom zápasu, čo eliminuje problém s neúplnými alebo neaktuálnymi údajmi. Tento prístup umožňuje efektívnejšie a presnejšie modelovanie výkonnosti tímu s ohľadom na aktuálny stav jeho kádra. Táto sieť je trénovaná pomocou metódy **autoenkóder** čo znamená že sa snaží rekonštruovať skompri-mované dáta, čo by malo mať za následok, že konvolučné jadrá sa naučia lepšie **komprimovať dáta bez straty podstatných informácií**.

Enkodér: Komprimuje pôvodné príznaky hráčov do latentního vektoru, ktorý je menší a efektívnejší.

Latentní vektor: Tento komprimovaný vektor obsahuje kľúčové informácie a je použitý ako vstup do predikčného modelu. Příklad pro tým 1: Latentní vektor může být [0.78, 0.8, 0.73, ...]

Rekonstrukce: Během tréninku slouží k ověření, že komprese a dekomprese neztrácí důležité informace.




Obrázok 4.3: Konvolučná neurónová sieť trénovaná s využitím autoenkodéra. Cieľom siete je naučiť sa efektívne komprimovať dáta do jednorozmerného vektora, pričom sa snaží zachovať maximum informácií o pôvodných zostavách hráčov jednotlivých tímov. Premenná H označuje počet hráčov v matici, zatiaľ čo premenná P reprezentuje počet príznakov pre každého hráča. Tretou dimenziou vstupných dát je premenná PH , ktorá symbolizuje posty (pozície na ihrisku) jednotlivých hráčov, pričom informácie o pozícii sú rozkopírované naprieč celým riadkom. Tento obrázok (respektíve ľavá časť) odpovedá červenej časti v obrázku 4.2


Po dokončení tréningu siete, ktorého priebeh loss môžete vidieť na grafe 4.4, je časť dekodéra odstránená. Namiesto nej je pripojená plne prepojená vrstva, ktorá sa ďalej dotrénuje. Tento proces je ilustrovaný na obrázku 4.2 v zelenej časti. Výstupom siete sú pravdepodobnosti predpovedaných udalostí, ktoré sa ďalej používajú ako príznak na úrovni tímu. Pôvodne bol prístup neurónovej siete zameraný na súbežné tréningovanie, kde 1D vektor (výstup) z konvolučných vrstiev bol ihneď konkatenovaný s dátami na úrovni tímu, a následne pripojený k plne prepojeným vrstvám, pričom **tréningovanie prebiehalo simultánne pre oba datasety (na úrovni hráčov aj tímov)**. Loss funkcia bola počítaná súhrnne pre oba datasety. Avšak, tento prístup nebol úspešný, najmä kvôli obmedzenému množstvu dát a veľkému počtu parametrov (keďže sa používali oba datasety súčasne, čo pridalo viac príznakov), čo ma odradilo od ďalších pokusov.

4.2.3 Architektúra a tréningovanie neurónovej siete

Pri návrhu modelu neurónovej siete som sa rozhodol pre jednoduchú architektúru s ohľadom na limitovaný objem dostupných dát, ktoré sú pre efektívne učenie neurónových sietí zvyčajne nevyhnutné vo veľkých množstvách. Vzhľadom na rozsiahlejší súbor príznakov a súčasné zameranie na minimalizáciu počtu parametrov som sledoval osvedčenú prax, ktorá odporúča mať **približne 10 vzorkov na každý parameter modelu**, aby sa zabezpečila jeho robustnosť a odolnosť voči pretrénovaniu.



Obrázok 4.4: Graf znázorňuje pokles loss počas tréovania **autoenkodéra**. Počas 175 epoch dochádza k rýchlemu poklesu straty, čo naznačuje efektívne učenie a optimalizáciu siete. Z grafu je zrejmé, že model konverguje k minimu validačnej loss, čo korešponduje s návrhom algoritmu.



Obrázok 4.5: Architektúra neurónovej siete zobrazuje predspracovanie dát na úrovni hráčov pomocou konvolučnej neurónovej siete, ktorá je podrobne popísaná na obrázku 4.3. Po spracovaní sú tieto dáta kombinované s dátami na úrovni tímu. Celkový spojený dataset potom prechádza cez sériu plne prepojených vrstiev, ktoré obsahujú prvky Leaky ReLU a Dropout, čím sa minimalizuje riziko pretrénovania. Výstupom siete je predikcia výsledkov pomocou sigmoidnej aktivačnej funkcie.

V sieti sú použité len 3 plne prepojené skryté vrstvy, regularizačné techniky a aktivačná funkcia **Leaky ReLU**. V štandardnej funkcii ReLU je každý záporný vstup mapovaný na nulu, čo môže viesť k mŕtvym neurónom počas tréningu, najmä ak veľká časť neurónov skončí so zápornými vstupmi. LeakyReLU umožňuje malý nenulový gradient, pri záporných hodnotách vstupov, čo pomáha udržať neuróny pri živote počas celého procesu tréovania.

Parametre neurónovej siete boli optimalizované systematickým experimentovaním, pričom najlepšie výsledky boli postupne ukladané.

Parameter	Hodnota
Learning Rate	0.0001
Epochy	175
Batch Size	32
Optimalizátor	Adam
Strata (Loss Function)	Binárna krížová entropia
Dropout Rate	0.3

Tabuľka 4.2: Konfigurácia neurónovej siete. Hyperparametre boli optimalizované postupnou metódou, pri ktorej sa menil vždy len jeden parameter a následne sa sledoval a hodnotil vplyv tejto zmeny na výkonnosť modelu. Tento prístup umožnil identifikovať efektívne nastavenie pre model.

Podoba loss funkcie


Loss funkcia je definovaná ako kombinácia binárnej krížovej entropie a dekorelačného termu. Táto funkcia je určená na trestanie modelu, ak sú jeho predikcie príliš blízko k inverzii kurzov bookmakera, tzv. šanciam na výhru. Koefficient c určuje intenzitu dekorelačného termu. Matematicky to možno vyjadriť ako:

$$L(y_{\text{true}}, y_{\text{pred}}, o, c) = \sum_{i=1}^N \left[\text{BCE}(y_{\text{true},i}; y_{\text{pred},i}) - c \cdot \left(y_{\text{pred},i} - \frac{1}{o_i} \right)^2 \right] \quad (4.1)$$

kde:

- y_{true} sú skutočné výstupné hodnoty,
- y_{pred} sú predpovedané výstupné hodnoty modelu,
- o predstavuje kurzy poskytované bookmakerom,
- c je konštanta, ktorá upravuje vplyv dekorelačného členu,
- BCE označuje binárnu krížovú entropiu,
- N je počet vzoriek, na ktorých sa výpočet vykonáva.

Grafy na obrázku 4.6 poskytujú vizualizáciu vývoja hodnoty loss a presnosti počas tréningu neurónovej siete. Prvý graf prezentuje dve krivky. Jedna reprezentuje loss pri tréningu a druhá pri validácii. Druhý graf zobrazuje presnosť modelu na tréningových a validačných dátach. Z grafu je zrejmé, že model konverguje k minime validačnej loss, čo korešponduje s návrhom algoritmu. Plynulosť kriviek loss funkcie naznačuje, že napriek menšej batch size (dávke) dát použitej v každom kroku tréningu, výsledky sú stabilné a pravdepodobnosť veľkých výkyvov v tréningovom procese je nízka. Pokles validačnej chyby indikuje, že model sa úspešne učí a zlepšuje svoje predpovede.



Obrázok 4.6: Loss a presnosť neurónovej siete počas tréningovania

4.2.4 Konfigurácia modelu RandomForest

Model Random Forest bol implementovaný s využitím knižnice *sklearn*. Na optimalizáciu hyperparametrov tohto modelu sa uplatnil prístup **GridSearchCV**. Robustný nástroj z knižnice *scikit-learn*, určený na systematické prehľadávanie priestoru možných nastavení. Metóda GridSearchCV podrobne preverí rôzne kombinácie hyperparametrov prostredníctvom procesu zvaného mriežkové vyhľadávanie, pričom každú potenciálnu konfiguráciu modelu testuje a hodnotí na základe preddefinovaných kritérií. Tento prístup umožňuje identifikovať optimálne nastavenie hyperparametrov pre maximálnu výkonnosť modelu. Uvádzam tabuľku s konfiguráciou hyperparametrov použitých v modeli Random Forest:

Parameter	Hodnota
n_estimators	471
max_depth	121
min_samples_split	18
min_samples_leaf	16
max_features	sqrt

Tabuľka 4.3: Konfiguračné parametre pre model Random Forest. Hyperparametre boli optimalizované pomocou metódy GridSearchCV, ktorá systematicky prehľadáva a porovnáva súbor možných nastavení parametrov, aby identifikovala najúčinnnejšiu kombináciu pre maximálny výkon modelu.

Popis jednotlivých parametrov:

- **n_estimators**: Označuje celkový počet stromov v lese. Zvyčajne platí, že viac stromov zvyšuje presnosť, ale tiež čas na tréningovanie a predikciu.
- **max_depth**: Určuje maximálnu hĺbku, do ktorej môže každý strom rásť. Obmedzenie hĺbky môže pomôcť zabrániť preučeniu.
- **min_samples_split**: Najmenší počet vzoriek potrebných na rozdelenie vnútorného uzla. Vyššie hodnoty bránia vytváraniu uzlov, ktoré rozdeľujú príliš malé dátové množiny.

- **min_samples_leaf**: Najmenší počet vzoriek, ktoré musia byť v listovom uzle. Tento parameter zabezpečuje, aby listové uzly obsahovali dostatočný počet vzoriek, čím sa predchádza preučeniu.
- **max_features**: Určuje počet príznakov, ktoré sa majú zväžiť pri vyhľadávaní najlepšieho rozdelenia v každom uzle.

Random Forest je z dôvodu použitia externej knižnice „black box“ model, čo znamená, že interné procesy rozhodovania a trénovania nie sú priamo prístupné alebo transparentné pre používateľa. Keď sa využíva metóda `.fit()`, model sa automaticky natrénuje na základe poskytnutých trénovacích dát. Detaily o jednotlivých stromoch a ich interakciách pri trénovaní nie sú jednoducho vizualizovateľné, pretože komplexné dáta sa spracúvajú interne a model sa vracia ako celok bez poskytnutia vhladu do procesu trénovania jednotlivých stromov alebo ich rozhodovacích kritérií.

4.2.5 Konfigurácia modelu XGBoost

Model XGBoost bol implementovaný prostredníctvom knižnice *xgboost*. Ako pri modeli Random Forest, aj tu sa využila technika **GridSearchCV** na **optimalizáciu hyperparametrov** modelu XGBoost. Následuje prehľad vybraných konfiguračných parametrov, ktoré boli optimalizované pre model XGBoost:

Hyperparameter	Hodnota
n_estimators	300
max_depth	52
learning_rate	0.05
subsample	0.85714
min_child_weight	0.1
colsample_bytree	0.8
lambda	0.5

Tabuľka 4.4: Konfiguračné parametre pre model XGBoost. Hyperparametre boli optimalizované pomocou metódy GridSearchCV, ktorá systematicky prehľadáva a porovnáva súbor možných nastavení parametrov, aby identifikovala najúčinnnejšiu kombináciu pre maximálny výkon modelu.

- **n_estimators**: Označuje počet stromov, ktoré sa majú vytvoriť. Viac stromov môže viesť k lepšiemu výkonu, ale tiež k riziku preučenia.
- **max_depth**: Určuje maximálnu hĺbku každého stromu. Hlbšie stromy môžu model zložitejším a schopným zachytiť viac jemných rozdielov v dátach, avšak zvyšujú riziko preučenia.
- **learning_rate**: Tento parameter kontroluje, aký rýchly bude učebný proces. Nižšie hodnoty znamenajú pomalšie učenie, ale môžu pomôcť v konvergencii modelu.
- **subsample**: Určuje frakciu vzoriek použitých na trénovanie každého stromu. Hodnoty menej ako 1.0 môžu viesť k väčšej diverzite stromov a môžu pomôcť v prevencii preučenia.

- `min_child_weight`: Kontroluje minimálnu váhu potrebnú na vytvorenie nového uzla v strome. Vyššie hodnoty môžu viesť k jednoduchším modelom.
- `colsample_bytree`: Určuje frakciu príznakov použitých na vytvorenie každého stromu. Podobne ako *subsample*, môže prispieť k diverzite modelu.
- `lambda`: Tento regularizačný parameter môže pomôcť znížiť preučenie prostredníctvom pridania penalizácie na veľké váhy v modeli.

Podobne ako v prípade modelu RandomForest, aj tu proces tréovania nie je ľahko vizualizovateľný kvôli využitiu modelu ako súčasti externej knižnice, ako je podrobne vysvetlené v časti 4.2.4.

4.3 Transformácia pozápasových štatistík

Tímové štatistiky ako strely na bránu, rohové kopy, alebo prihrávky sa získajú až po odohraní zápasu. Z tohto dôvodu ich nie je možné priamo použiť pri tréovaní modelov, ktoré sa snažia predpovedať výsledky zápasov vopred. Aby sa mohli tieto údaje efektívne využiť, premenil som ich na **vážené priemery z predchádzajúcich zápasov**. Tieto priemery pomáhajú pochopiť súčasnú výkonnosť a formu tímu, pričom **novšie zápasy majú väčšiu váhu ako staršie**. Napríklad, ak potrebujem príznak „počet striel na bránu“ pre tím A, vypočítam vážený priemer počtu striel na bránu za posledných n zápasov. Výslednú hodnotu následne použijem ako príznak pre predikciu budúceho zápasu.

Tento prístup sa aplikoval pre domáce aj hostujúce tímy, aby sa získal ucelený obraz o ich aktuálnej forme. Na poskytnutie lepšieho pohľadu na výkonnosť tímov sa vypočítali dva typy priemerov: **"dlhodobá forma"**, ktorá zahŕňa **posledných 20 zápasov**, a **"krátkodobá forma"**, ktorá sa odvodzuje z **posledných 5 zápasov**. Tento dvojité prístup umožňuje modelom získať informácie o dlhodobej stabilite a krátkodobej dynamike výkonnosti tímov.

4.4 Porovnanie charakteristík rôznych futbalových líg

Analýzovaním dát z **rôznych futbalových líg** sa odhalia faktory, ktoré môžu významne ovplyvniť výsledky predikcií. Skúma sa, či existujú výrazné rozdiely medzi ligami alebo či sú charakteristiky futbalu v popredných svetových ligách podobné. V tabuľke 4.5 sú uvedené apriórne pravdepodobnosti predpovedaných udalostí pre jednotlivé ligy. Z týchto údajov je zrejmé, že **rozdiely môžu byť výrazné**, napríklad pri udalostiach „počet gólov viac ako 2.5“, kde sa pravdepodobnosti líšia v rozmedzí od približne 47% do 60%. Tento zistený fakt naznačuje potrebu **zahrnúť do modelu informácie o konkrétnej lige**. Ďalším pozoruhodným aspektom je domáca výhoda, kde pravidelnosť víťazstiev alebo neprehry domácich tímov je oveľa vyššia v porovnaní s víťazstvami hostí. Preto je nevyhnutné **zahrnúť do predikčných modelov príznaky odrážajúce túto domácu výhodu**.

4.5 Optimalizácia štruktúry dát

Táto sekcia je venovaná exploratívnej analýze dát s primárnym cieľom dosiahnuť lepšie porozumenie datasetu, skúmať jeho základné charakteristiky a vyčleniť dôležité informácie. Cieľom je odfiltrovať prvky, ktoré nemajú priamy vplyv na predikované udalosti zápasu,

Liga	V/M 2.5	ODG	1	1X	2	X2	Počet zápasov
Premier League	52.76%	51.01%	44.96%	68.63%	33.37%	55.04%	4680
Ligue 1	48.19%	50.74%	44.21%	71.04%	28.96%	55.79%	4576
Bundesliga	58.05%	56.88%	45.29%	69.77%	30.23%	54.71%	3771
Eredivisie	59.54%	56.83%	45.92%	69.57%	30.43%	54.08%	3717
Primeira Liga	47.78%	48.11%	44.81%	68.74%	31.26%	55.19%	3573
Serie A	51.92%	53.53%	43.74%	69.25%	30.75%	56.26%	4680
LaLiga	49.72%	50.48%	46.33%	71.57%	28.43%	53.67%	4688

Tabuľka 4.5: Prehľad apriórnych pravdepodobností predpovedaných udalostí podľa líg za obdobie 2012 až 2023. Tabuľka ukazuje, ako sa pravdepodobnosti pre jednotlivé udalosti líšia medzi rôznymi ligami, čo poukazuje na významné rozdiely v štýle a charaktere hry. Napríklad, pravdepodobnosti pre udalosť „počet gólov viac ako 2.5“ (V/M 2.5) sa pohybujú od 47% do 60%. Ligy ako Bundesliga a Eredivisie majú výrazne vyššie pravdepodobnosti, že oba tímy skórujú (ODG), oproti Primeira Lige. Tieto údaje sú dôležité pre analýzu trendov a môžu pomôcť pri výbere stratégií pre stávky alebo predpovede. Vysvetlenia skratiek: V/M 2.5 znamená počet gólov viac ako 2.5, ODG znamená že oba tímy dajú gól, 1 reprezentuje výhru domácich, 1X znamená neprehru domácich, 2 predstavuje výhru hostí, X2 je neprehra hostí.

ako napríklad počet žltých a červených kariet, aby sa zabránilo nepotrebnému komplikovaniu modelu a riziku jeho pretrénovania. Boli preskúmané metódy ako korelačná analýza a postupná selekcia s cieľom efektívne redukovať dimenzionalitu datasetu, čo je podrobne rozpracované v nasledujúcich podsekcích.

4.5.1 Výber príznakov na základe korelácie

Pri tejto technike boli vypočítané korelácie príznakov s **ground truth** (predikovanými udalosťami) a následne bol vypočítaný rebríček absolútnych hodnôt týchto korelácií pre každý príznak. V tabuľke 4.6 sú uvedené prvky s najvyššou a najnižšou koreláciou.

Je dôležité zdôrazniť, že nižšia korelácia príznaku A v porovnaní s príznakom B (myslí sa tým korelácia týchto príznakov s ground truth) neznamená nevyhnutne, že príznak A je menej užitočný. V niektorých prípadoch sa môže objaviť situácia, kde konkrétny príznak preukazuje nízku koreláciu s ground truth. Avšak, v kombinácii s inými príznakmi, tento príznak môže výrazne prispieť k zlepšeniu predikčných schopností modelu. Tento fenomén vyzdvihuje význam komplexného hodnotenia príznakov, kde kombinácia príznakov v spojení s logickým uvažovaním môže viesť k výrazne lepším výsledkom. Korelácia neberie do úvahy kontext a možný význam príznaku v špecifickej situácii. Príznak s nižšou koreláciou môže byť veľmi dôležitý v určitých špecifických prípadoch alebo podmienkach, ktoré nie sú zastúpené v celkovej korelácii. Cieľom je odfiltrovať príznaky s takmer nulovou koreláciou, ktoré s veľkou pravdepodobnosťou predstavujú šum.

4.5.2 Metóda postupnej selekcie

Následne bola aplikovaná metóda postupnej selekcie príznakov založená na iteratívnom skúšaní. Tento prístup spočíva vo výbere základnej množiny príznakov, ktorá obsahuje nevyhnutné a potenciálne významné charakteristiky dát. Následne boli postupne pridávané

Najviac korelované príznaky s ground truth	Priemerná korelácia	Najmenej korelované príznaky s ground truth	Priemerná korelácia
result_1_pst	0.39569	ht_h2h_at_blocked_shots	0.00171
result_X2_pst	0.39569	ath_h2h_total_shot_outsidebox	0.001694
result_1X_pst	0.39464	at_h2h_ht_shots_outsidebox	0.00167
result_2_pst	0.39464	ath_h2h_diff_shots_outsidebox	0.001646
lt_diff_goals_ma_g	0.38010	ht_h2h_at_ball_possession	0.001608
lt_diff_goals_ma_g	0.33907	ht_h2h_at_total_shots	0.001597
ht_elo	0.33309	ht_h2h_at_shots_on_goal	0.000985
at_elo	0.31813	ath_h2h_total_shots_on_goal	0.000923
st_diff_goals_ma_g	0.30923	at_h2h_ht_shots_on_goal	0.000884
ht_win_rate	0.28403	ath_h2h_diff_shots_on_goal	0.000845
lt_diff_goals_ma_c	0.27826	st_total_goals_c	0.000086

Tabuľka 4.6: Príznaky s najvyššou a najnižšou koreláciou vo vzťahu ku ground truth v datasete. Jednotlivé vysvetlenia k týmto príznakom je možné nájsť v prílohe **B**

ďalšie príznaky, pričom bol dôkladne monitorovaný vplyv týchto doplnkov na výkonnosť modelu. V každej iterácii bola pridaná podmnožina nejakých súvisiacich príznakov a hodnotené bolo, či toto pridanie viedlo k zlepšeniu alebo zhoršeniu modelu.

Rozhodnutie o ponechaní alebo odstránení príznaku z modelu bolo založené na jeho vplyve na predikčnú presnosť a očakávaný profit. Príznak bol ponechaný vo finálnej množine iba vtedy, keď jeho pridanie konzistentne zlepšovalo výsledky modelu. Tento proces bol opakovaný až kým nebola dosiahnutá sada príznakov, ktorá vykazovala maximálnu predikčnú schopnosť.

Týmto spôsobom bol dosiahnutý cieľ vyhnúť sa problémom spojeným s nadmernou komplexnosťou modelu, pri súčasnom zachovaní dôležitých informácií nevyhnutných pre spoľahlivú predikciu.

4.6 Riešenie problému chýbajúcich dát

Pred samotným spracovaním algoritmom je nevyhnutné, aby boli dáta kompletné a bez chýbajúcich údajov. V oblasti šport je získanie kompletných dátových súborov náročná úloha, predovšetkým z dôvodu nedostupnosti niektorých informácií. Tieto medzery spôsobujú problémy, preto ich treba nejakým spôsobom opraviť.

Chýbajúce dáta možno doplniť, pričom chýbajúce dáta možno predpovedať rôznymi metódami. Spôsob, akým sa chýbajúce dáta dopĺňajú alebo odstraňujú, môže spôsobiť vážne skreslenie, ktoré sa zavedie do modelu. Boli uplatnené rôzne metódy na vkladanie hodnôt, aby sa zachoval čo najväčší objem dát. Tento proces zohľadňoval kontext a štruktúru dát. V prípadoch, kde pôvodné zdroje označovali hodnotu nula ako neúplnú (napríklad „null“), bolo nutné túto reprezentáciu upraviť (Teda nahradiť neúplnú hodnotu 0). Pre prípady s neplatnými alebo chýbajúcimi údajmi bol použitý substitučný indikátor -999, ktorý je vhodný pre modely tolerujúce odľahlé hodnoty. Takýmito modelmi sú napríklad **Random Forest** a **XGBoost**. V rámci predspracovania dát pre neurónovú sieť som sa spočiatku pokúsil použiť jednoduchú lineárnu regresiu na doplnenie chýbajúcich hodnôt. Avšak tento prístup viedol k signifikantnému skresleniu v datasete, čo ma viedlo k hľadaniu alternatív.

Následně som experimentoval s nahrazením chýbajících hodnôt **priemernými hodnotami**, ktoré sa dopočítali na základe dostupných dát z príslušnej ligy a sezóny pre daný tím. Táto metóda priniesla zlepšenie a výsledky boli uspokojivé. Ideálne by však bolo manuálne a dôkladne doplniť chýbajúce hodnoty v dátach reálnymi hodnotami, čo by však vyžadovalo značné množstvo času. Preto by zlepšenie kvality dát bolo cenným prínosom pre budúce práce v tejto oblasti.

Celkový model

1. Autoenkodér:

- **Enkodér:** Komprimuje príznaky hráčů do latentního vektoru.
- **Dekodér:** Používá se během tréninku autoenkodéru k ověření, že komprese zachovává důležité informace.
- **Trénink autoenkodéru:** Autoenkodér se trénuje, aby se naučil efektivně komprimovat příznaky hráčů.

2. Nahrazení dekodéru:

- Po tréninku autoenkodéru se dekodér odstraní.
- Na místo dekodéru se přidá plně propojená vrstva.

3. Plně propojená vrstva:

- Tato vrstva se dotrénuje na základě cílových hodnot (např. výsledků zápasů) a produkuje transformované hráčské příznaky.
- Tyto transformované příznaky mohou být pravděpodobnosti různých událostí (např. individuální výkon hráče).

4. Konkatenace příznaků:

- Transformované příznaky hráčů (latentní vektory z plně propojené vrstvy) jsou spojeny (konkatenovány) s týmovými příznaky.
- Týmové příznaky mohou zahrnovat údaje jako průměrný počet gólů, forma týmu, zda hraje doma/venku, atd.

5. Finální predikční model:

- Spojené (konkatenované) příznaky jsou použity jako vstupy pro finální predikční model (RandomForest, NNET, XGBoost).
- Tento model produkuje konečné pravděpodobnosti událostí (např. výhra domácího týmu, remíza, výhra hostujícího týmu).

Příklad výpočtu korelace

Řekněme, že máme následující data:

- **Ground Truth (výsledek zápasu):**
 - `[1, 0, 1, 0, 1, 1, 0, 0, 1, 0]` (1 = výhra, 0 = prohra)
- **Příznak `result_1_pst`:**
 - `[0.8, 0.2, 0.7, 0.3, 0.9, 0.85, 0.4, 0.35, 0.75, 0.25]`

Výpočet Pearsonova korelačního koeficientu

1. Průměry:

- Průměr ground truth: $\bar{Y} = 0.5$
- Průměr `result_1_pst`: $\bar{X} = 0.55$

2. Korelační koeficient:

$$r = \frac{\sum (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum (X_i - \bar{X})^2 \sum (Y_i - \bar{Y})^2}}$$

• Čítec:

$$\sum (X_i - \bar{X})(Y_i - \bar{Y}) = (0.8 - 0.55)(1 - 0.5) + (0.2 - 0.55)(0 - 0.5) + \dots + (0.25 - 0.55)(0 - 0.5)$$

• Jmenovatel:

$$\sqrt{\sum (X_i - \bar{X})^2 \sum (Y_i - \bar{Y})^2}$$

3. Výpočet:

- Výsledný korelační koeficient r by byl kolem hodnoty uvedené v tabulce (0.39569).

Kapitola 5

Experimentálny dizajn a ciele

Táto kapitola podáva prehľad série experimentov zameraných na analýzu predikčných modelov z viacerých perspektív. Hlavnými cieľmi bolo:

1. **Vývoj nových predikčných modelov:** Navrhnutie a testovanie modelov s cieľom prekonať výkonnosť základných modelov v predpovediach udalostí.
2. **Analýza významu historických dát:** Overenie, do akej miery majú historické dáta vplyv na presnosť predikcií.
3. **Vplyv kurzov na predikcie:** Preskúmanie, ako kurzy ponúkané stávkovými kancelármi ovplyvňujú predikčné modely a ich schopnosť generovať predpovede.
4. **Hodnotenie trhovej efektivity:** Testovanie modelov na stávkovom trhu.

Tieto experimenty sú kľúčové pre pochopenie možností predikčných modelov v oblasti športových stávok a pre identifikáciu faktorov, ktoré sú rozhodujúce pre úspešné predpovede v tomto dynamickom a často nepredvídateľnom prostredí.

5.1 Hodnotiace metriky

Predstavenie a popis hodnotiacich metrík, ktoré sú kľúčové pre posúdenie účinnosti modelov, sa nachádza v nasledujúcich podkapitolách. Tieto metriky umožňujú objektívne hodnotiť a porovnávať výkonnosť rôznych predikčných modelov a sú nevyhnutné pre správnu interpretáciu výsledkov.

5.1.1 Presnosť a jej interpretácia

Presnosť predstavuje kľúčový ukazovateľ výkonnosti pre klasifikačné modely a je nevyhnutné ju zohľadniť pri hodnotení modelov. Avšak, pri jej interpretácii je potrebná obozretnosť, najmä vzhľadom na **ignorovanie apriórnych pravdepodobností** tried. Vysoká presnosť, napríklad 97%, nemusí poskytovať relevantný uhol pohľadu bez kontextu jednotlivých tried v datasete. V situácii, keď apriórna pravdepodobnosť dominantnej triedy dosahuje 97%, môže byť dosiahnutie takejto presnosti triviálne prostredníctvom naivného modelu, ktorý konzistentne predpovedá túto triedu.

V praxi to znamená, že model s presnosťou 97% nemusí byť nutne lepší alebo „ziskovejší“ v porovnaní s modelom s presnosťou 30%, keďže ten môže efektívne identifikovať menej

Metrika acc_{scaled} poskytuje lepší zhodnocení výkonnosti predikčního modelu tím, že zohledňuje kurzy nabízené sázkovými kanceláři. To znamená, že model, který správně predikuje zápasy s vyššími kurzy, bude mít vyšší hodnotu této metricky, což naznačuje jeho efektivitu a potenciál pro generování zisku.

pravdepodobné udalosti s vyššími kurzami, čo by mohlo viesť k vyššej celkovej ziskovosti modelu.

Pre adekvátne zhodnotenie presnosti je vhodné zaviesť aj metriku, ktorá zohľadňuje kurzy ponúkané sázkovými kancelármi. **Presnosť modelu možno efektívne preškálovať s ohľadom na kurz**, napríklad 2, čo implikuje, že presnosť pod 50% by viedla k strate, zatiaľ čo presnosť nad 50% by indikovala zisk, a teda vyššie hodnoty indikujú lepšiu výkonnosť modelu. Túto preškálovanú presnosť možno vypočítať nasledujúcim vzorcom:

$$acc_{scaled} = \left(\frac{1}{N} \sum_{i=1}^N o_i \right) \times \frac{acc}{s} \tag{5.1}$$

kde:

- N - predstavuje počet správne predpovedaných udalostí,
- o_n - označuje kurz n-tého správne predpovedaného zápasu,
- acc - je celková presnosť modelu.
- s - kurz na ktorý škálujem danú presnosť, v tomto prípade 2

Výpočet metricky

1. Průměrný kurz správně predikovaných zápasů:

$$\frac{1}{N} \sum_{i=1}^N o_i = \frac{1}{5} (2.5 + 1.8 + 3.0 + 2.2 + 1.9) = \frac{1}{5} \times 11.4 = 2.28$$

2. Preskalovaná presnosť:

$$acc_{scaled} = 2.28 \times \frac{0.5}{2} = 2.28 \times 0.25 = 0.57$$

Preskalovaná presnosť $acc_{scaled} = 0.57$:

- Tento výsledok znamená, že po zohľadnení kurzů má model efektívnu presnosť 57%.
- Vyšší preskalovaná presnosť ukazuje, že model nejenže správne predikuje výsledky, ale také že správne predikcie jsou často pro zápasy s vyššími kurzy (což je pozitivní pro sázející).

5.1.2 Návratnosť investície

Návratnosť Investície (Return on Investment, skrátene ROI) je ukazateľom **efektivity investície**, ktorý počíta **pomer medzi ziskom (alebo stratou) a pôvodnou investíciou**, teda vyššia hodnota indikuje väčší zisk. Vyjadruje sa obvykle v percentách a je definovaná ako:

$$ROI = \left(\frac{\text{Celkový zisk} - \text{Celková investícia}}{\text{Celková investícia}} \right) \times 100\% \tag{5.2}$$

kde:

- **Celkový zisk** predstavuje sumu výhier získaných zo všetkých uskutočnených stávok.
- **Celková investícia** je suma všetkých finančných prostriedkov vložených do stávok.

V kontexte sázkových modelov ROI poskytuje hlbkový pohľad na ziskovosť modelu vzhľadom na uskutočnené stávky.

5.1.3 Brierovo skóre

Brierovo skóre predstavuje komplexnú metriku výkonnosti používanú na kvantifikáciu presnosti predpovedí vo forme pravdepodobností. Je obzvlášť užitočné v kontexte klasifikačných úloh, kde model poskytuje pravdepodobnosti príslušnosti k jednotlivým triedam. Brierovo skóre je definované ako **stredná kvadratická chyba medzi predpovedanými pravdepodobnosťami a skutočnými výsledkami**, pričom nižšie hodnoty indikujú lepšiu výkonnosť modelu. Vzorec pre výpočet Brierovho skóre je nasledovný:

$$\text{Brierovo Skóre} = \frac{1}{N} \sum_{i=1}^N (p_i - y_i)^2 \tag{5.3}$$

Příklad
Představme si následující údaje:
1. Celková investice: 1000 Kč (to je suma všech stávek, které byly vsazeny).
2. Celkový zisk: 1200 Kč (to je suma všech výher získaných z těchto stávek).
Vypočet ROI:
1. Výpočet zisku: Celkový zisk - Celková investice = 1200 Kč - 1000 Kč = 200 Kč
2. Výpočet ROI: $ROI = \left(\frac{200}{1000} \right) \times 100\% = 20\%$
Interpretace výsledku:
• ROI = 20%:
• Tento výsledek znamená, že na každých 100 Kč investovaných do stávek model přinesl zisk 20 Kč.
• ROI ve výši 20 % naznačuje, že investice byla zisková a model pro sázení je efektivní.

kde:

- N predstavuje celkový počet predikcií,
- p_i je predpovedaná pravdepodobnosť, že i -tý príklad patrí do pozitívnej triedy,
- y_i je skutočný výsledok pre i -tý príklad, kde pozitívnej triede zodpovedá hodnota 1 a negatívnej 0.

Brierovo skóre sa pohybuje od 0 do 1, kde 0 predstavuje dokonalú presnosť predikcií a 1 indikuje úplnú nepresnosť. Táto metrika umožňuje nielen posúdiť celkovú presnosť modelu, ale aj oceniť, ako dobre model kvantifikuje neistotu svojich predikcií. Brierovo skóre je preto cenné v situáciách, kde je dôležité nielen správne klasifikovať príklady, ale aj poskytnúť presný odhad pravdepodobnosti.

5.1.4 Metrika podobnosť bookmakera

Metrika *Podobnosť bookmakera* je navrhnutá na meranie rozdielu medzi pravdepodobnosťami predpovedanými modelom a odhadmi stávkových kancelárií. Vyjadruje, ako presne model odráža trhové očakávania, pričom nižšie hodnoty indikujú väčšiu zhodu. Výpočet je založený na kvadratických rozdieloch pravdepodobností modelu p_{model} a bookmakera p_{book} , ktoré sa určia takto:

Najskôr sa vypočíta marža (viz. sekcia 2.5.4) bookmakera m ako:

$$m = \left(\frac{1}{o} + \frac{1}{o'} \right) - 1, \quad (5.4)$$

kde o a o' sú kurzy pre udalosť a jej komplement (napríklad ak o je kurz pre udalosť „počet gólov viac ako 2.5“ tak potom o' je kurz pre udalosť „počet gólov menej ako 2.5“). Predpovedaná pravdepodobnosť bookmakera p_{book} udalosti o sa potom vypočíta ako:

$$p_{\text{book}} = \frac{1}{o} - \frac{m}{2}. \quad (5.5)$$

Celková *Podobnosť bookmakera* je definovaná ako stredná hodnota kvadratických rozdielov pre všetky pozorované udalosti:

$$\text{Podobnosť bookmakera} = \frac{1}{N} \sum_i^N (p_{\text{model},i} - p_{\text{book},i})^2 \quad (5.6)$$

kde N je počet predpovedaných zápasov. Nižšie hodnoty tejto metriky ukazujú, že predikcie modelu sú bližšie k pravdepodobnostiam odhadnutým stávkovými kanceláriami.

5.2 Vyhodnotenie modelov

V časti 3.4 som opísal 6 typov modelov, ktoré použijem v nasledujúcich experimentoch, ktoré sa budu hodnotiť a porovnávať.

Jednoduché (Simple):

- Simple-RF
- Simple-XGB
- Simple-NNET

Pokročilé (Advanced):

- Advanced-RF
- Advanced-XGB
- Advanced-NNET

Pre každý z typov predikcie boli vytvorené rozličné konfigurácie, ktoré boli vyhodnotené pre 3 typy udalostí: „počet gólov viac ako 2.5“, „oba tímy dajú gól“, a „výsledok zápasu“. Rôznorodosť konfigurácií spočíva v nastaveniach parametrov, váhovania vzorkov, alebo v architektúre vrstiev v prípade neurónových sietí. Je dôležité spomenúť, že **nie všetky zápasy boli zahrnuté vo výsledkoch. Modely sú limitované pravidlami**, ktoré určujú, pre ktoré zápasy by mali filtrovať predpovede. Napríklad, ak je očakávaný profit zo zápasu záporný, tak takáto predikcia sa nezapočíta do výsledného setu.

Dátová sada obsahuje približne 25,000 zápasov v tréningovej sade a 2,000 v testovacej sade. Nebolo možné použiť viac testovacích dát, pretože by to vzhľadom na štýl tréningu neumožnilo dokončiť tréning v rozumnom čase, ako je uvedené v sekcii 3.5. Navyše, použitie väčšieho objemu dát by nebolo vhodné kvôli veľkému množstvu chýbajúcich údajov v tréningovej sade z rokov 2011 až 2014, keďže mnohé štatistiky používané pri predikcii ešte neboli dostupné.

Pro každý zápas se vypočítá očekávaný profit na základě pravděpodobností predikovaných modelem a kurzů nabízených sázkovou kanceláří.

Pouze zápasy s kladným očekávaným profitem se započítávají do hodnocení modelu.

Pokud je očekávaný profit záporný, zápas se nezapočítá do hodnocení modelu.

To znamená, že celková přesnost modelu, návratnost investice (ROI) a další metricky se počítají jen z těchto zápasů.

5.3 Hodnotenie v porovnaní s kurzovými stávkami

Modely boli hodnotené aj na základe ich schopnosti generovať zisk prostredníctvom stávk na trhoch s kurzami, využívajúc predikcie modelu. Táto práca sa zameriava na desatinné kurzy, reprezentované ako $o_n \in \mathbb{R}, o_n > 1$, kde n označuje špecifickú udalosť, na ktorú sa stávka umiestňuje, a o predstavuje ponúkaný kurz. Napríklad, kurz $o_{X2} = 3.42$ naznačuje, že stávka 1 jednotky na výsledok „hostia neprehrajú“ by v prípade výhry priniesla návrat 3.42 jednotiek, čo znamená čistý zisk 2.42 jednotiek.

Očakávaný zisk z takéhoto prístupu môže byť vypočítaný využitím predikovanej pravdepodobnosti udalosti p_n a porovnaním s ponúkaným kurzom o_n . Očakávaný zisk $E[Z]$ pre danú stávku je možné vyjadriť ako:

$$E[Z] = (p_n \cdot (o_n - 1)) - (1 - p_n) \quad (5.7)$$

kde:

- p_n je predikovaná pravdepodobnosť výhry udalosti n ,
- o_n je kurz ponúkaný na udalosť n ,
- $E[Z]$ je očakávaný zisk z jednotkovej stávky.

Tento výpočet zohľadňuje nielen potenciálny zisk z výhry na základe kurzu, ale aj pravdepodobnosť prehry. Pozitívna hodnota očakávaného zisku naznačuje, že stávka má hodnotu nad rámec rizika, čo umožňuje vytvoriť výhodu proti bookmakerovi. V praxi je **klúčové**, aby modely čo najlepšie odhadovali pravdepodobnosti udalostí, aby očakávaný zisk presne reflektoval potenciálnu ziskovosť stávok.

Představme si následující scénář:

- Predikovaná pravdepodobnosť výhry tímu A (p_n): 0.6 (60%)
- Kurz na výhru tímu A (o_n): 3.0

Výpočet

1. První část vzorce (očekávaný zisk z výhry):

$$p_n \cdot (o_n - 1) = 0.6 \cdot (3.0 - 1) = 0.6 \cdot 2 = 1.2$$

2. Druhá část vzorce (očekávaná ztráta z prohry):

$$-(1 - p_n) = -(1 - 0.6) = -0.4$$

3. Celkový očekávaný zisk:

$$E[Z] = 1.2 - 0.4 = 0.8$$

48

Interpretace výsledku

- $E[Z] = 0.8$:
 - Tento výsledek znamená, že očekávaný zisk z jednotkové sázky je 0.8 jednotky (např. 0.8 Kč).
 - Kladný očekávaný zisk znamená, že sázení na tento výsledek by mělo být dlouhodobě ziskové.

Kapitola 6

Vyhodnotenie experimentov

V tejto kapitole sú predstavené výsledky experimentov. Keďže ide o rôzne typy modelov, viacero udalostí a výsledkov je veľa, tak vyzdvihnem tie najzaujímavejšie poznatky. Prvým krokom experimentu bol **test vplyvu historických dát na presnosť predikcií**. Ďalším krokom bolo zistiť **vplyv kurzov stávkových kancelárií na výsledky predikcií**. Ďalej sa porovnáva **výkonnosť implementovaných modelov** so základnými modelmi na základe metrík a ziskovosti opísanej v predchádzajúcej kapitole 5.1.


6.1 Vplyv historických dát na presnosť predikcií

Zameral som sa na skúmanie, do akej miery môže **zahrnutie výsledkov zápasov len z nedávnych sezón** vo vstupných dátach ovplyvniť presnosť predpovedí. Vychádzalo sa z predpokladu, že **tímy sa časom menia**, a teda výkony tímov spred desiatich či dvanástich rokov nie sú relevantné pre aktuálnu sezónu. V dôsledku toho by mali byť predikcie založené na aktuálnejších dátach presnejšie. Naopak, väčšie množstvo dát môže pomôcť modelom lepšie generalizovať a zároveň znižuje riziko pretrénovania.

Pre overenie tejto hypotézy sa pripravilo **dvanásť datasetov**, ktoré **postupne zahrňovali dáta z narastajúceho počtu starších sezón**. Prvý dataset obsahoval dáta zo všetkých dostupných dvanástich sezón (čiže všetky dostupné dáta), zatiaľ čo každý ďalší z nich zahŕňal dáta o jednu sezónu menej, až po posledný, ktorý obsahoval dáta len z posledných 2 sezón. Na tieto súbory dát sa aplikovali predikčné modely, ktoré boli predstavené v sekcii 3.4, a vyhodnotila sa ich presnosť a Brierovo skóre podľa metrík uvedených v sekcii 5.1, testované na vzorke 2000 zápasov.

Je dôležité zdôrazniť, že **táto analýza sa zameriava výlučne na klasickú presnosť predikcií** a tak isto sa jednotlivé predikcie nefiltrujú podľa očakávaného zisku ako som spomínal v sekcii 5.2. Cieľom je ukázať, ako sa presnosť modelov mení v závislosti od rozsahu a aktuálnosti zahrnutých historických dát. Na grafoch 6.1 je zobrazený vývoj presnosti a Brierovho skóre pre jednotlivé modely pri predpovediach troch vybraných udalostí.

Výsledky experimentu nepotvrdili hypotézu, keďže sa nezaznamenalo **žiadne významné zlepšenie v presnosti predpovedí pri zohľadnení len posledných sezón**, čo je možné vidieť na už spomenutých grafoch 6.1. Pre každý model sa ukázal byť optimálnejší rozdielny počet sezón, avšak tieto zistenia nie sú možné zovšeobecniť v rôznych scenároch. Rozdiely medzi týmito a ostatnými výsledkami neboli významné, s výnimkou prípadov, kde dátový súbor obsahoval len posledné dve sezóny, ktoré vykazovali najhoršie výsledky.



Obrázok 6.1: Porovnanie vplyvu historických sezón na presnosť a Brier skóre jednotlivých modelov pri predikcii udalostí „výsledok zápasu“ (VYS), „počet gólov viac ako 2.5“ (V/M 2.5) a „obaja dajú gól“ (ODG). V grafoch je tak isto vidieť, že najnižšie Brier skóre a najvyššiu presnosť dosahuje bookmaker, čo poukazuje na vysokú presnosť predikcií stávkových kancelárií.

Výsledok zápasu												
Advanced							Simple					
	NNet		RF		XGB		NNet		RF		XGB	
S	Acc	Brier	Acc	Brier	Acc	Brier	Acc	Brier	Acc	Brier	Acc	Brier
2	76.84	0.180	78.47	0.162	76.40	0.181	69.43	0.198	75.03	0.184	72.57	0.207
3	76.99	0.176	79.10	0.159	78.77	0.166	76.83	0.177	76.87	0.173	73.23	0.196
4	77.60	0.174	79.47	0.158	79.20	<i>0.163</i>	77.27	0.175	76.77	0.173	73.57	0.192
5	77.77	0.174	79.37	0.158	77.87	0.171	76.77	0.176	76.67	0.172	74.27	0.189
6	78.53	<i>0.167</i>	79.40	0.157	79.10	<i>0.163</i>	76.80	<i>0.174</i>	77.03	0.171	73.50	0.194
7	78.43	0.168	79.5	0.158	78.40	0.168	76.17	0.177	77.03	0.171	74.27	0.189
8	78.17	0.168	79.53	0.157	78.00	0.170	76.40	0.176	77.43	<i>0.169</i>	74.10	0.190
9	78.20	0.169	79.27	0.158	77.87	0.171	76.53	0.176	77.10	0.170	75.00	0.186
10	77.75	0.171	79.63	<i>0.156</i>	77.80	0.169	76.40	0.176	76.90	0.171	75.70	<i>0.181</i>
11	77.66	0.173	79.30	0.158	77.83	0.170	76.54	0.175	77.30	0.170	74.60	0.188
12	77.94	0.172	79.30	0.157	77.27	0.172	76.67	0.175	77.40	<i>0.169</i>	75.57	0.182

Tabuľka 6.1: Vplyv počtu sezón na výslednú predikciu udalosti „výsledok zápasu“ (VYS). Pokročilé (Advanced) modely sú konzistentne lepšie ako jednoduché (Simple). Znížený počet sezón nevedie nutne k vyššej presnosti modelov. Vo výsledkoch nie je vidieť žiaden vzťah medzi počtom sezón a výslednou presnosťou. Najhoršie hodnoty presnosti a Brier skóre pre modely Simple-NNET a Simple-XGB zdôrazňujú význam vhodnej selekcie príznakov a optimalizácie modelu. Kvôli kompaktnosti tabuľky som sa rozhodol uvádzať Brierovo skóre len s presnosťou na tri desatinné miesta, no veľká časť modelov sa odlišovala práve v hodnotách na štvrtej desatinnej pozícii.

Počet gólov viac ako 2.5												
Pokročilé							Jednoduché					
	NNet		RF		XGB		NNet		RF		XGB	
S	Acc	Brier	Acc	Brier	Acc	Brier	Acc	Brier	Acc	Brier	Acc	Brier
2	54.13	0.289	52.20	0.253	53.03	0.252	52.70	0.269	52.93	0.249	51.60	0.275
3	56.83	0.246	55.83	0.243	53.57	0.249	53.65	<i>0.245</i>	56.20	0.245	52.83	0.263
4	57.63	0.241	56.83	0.243	55.67	0.245	54.23	0.247	54.97	0.246	53.02	0.253
5	57.60	0.241	57.13	0.242	54.70	0.247	54.45	0.247	55.43	0.246	53.40	0.261
6	57.60	0.240	57.30	0.240	54.97	0.247	54.07	0.246	55.40	0.245	53.77	0.249
7	58.03	0.239	57.83	0.241	55.33	0.246	55.10	0.246	55.47	0.246	51.95	0.253
8	57.70	0.240	57.80	0.241	54.13	0.248	54.57	<i>0.245</i>	55.40	0.246	52.80	0.254
9	57.77	<i>0.238</i>	57.43	0.241	55.20	0.247	54.77	0.246	55.03	<i>0.244</i>	52.78	0.249
10	57.83	0.239	57.53	0.245	55.73	0.246	54.40	<i>0.245</i>	55.27	0.245	53.08	<i>0.248</i>
11	57.90	0.240	57.40	<i>0.239</i>	56.83	<i>0.244</i>	54.55	0.246	54.63	0.246	52.02	0.251
12	57.67	0.239	57.23	0.241	55.70	0.245	54.85	0.246	55.70	0.245	53.20	<i>0.248</i>

Tabuľka 6.2: Vplyv počtu sezón na presnosť a Brier skóre modelov pri predikcii udalosti „počet gólov viac ako 2.5“ (V/M 2.5). Zdá sa, že historické dáta neovplyvňujú výsledky tak výrazne ako kvalita príznakov. Rozličné modely dosiahli svoje najlepšie výsledky s rôznym počtom sezón, čo naznačuje, že pre túto konkrétnu predikciu neexistuje univerzálna optimálna veľkosť datasetu. Táto situácia môže naznačovať, že úspešnosť predikcie môže závisieť skôr od špecifických charakteristík dát ako od ich kvantity.

Obaja dajú gól												
Pokročilé							Jednoduché					
	NNet		RF		XGB		NNet		RF		XGB	
S	Acc	Brier	Acc	Brier	Acc	Brier	Acc	Brier	Acc	Brier	Acc	Brier
2	51.13	0.270	51.33	0.254	52.43	0.272	46.42	0.322	50.27	0.261	51.12	0.272
3	53.93	0.253	53.37	0.249	52.87	0.249	46.58	0.284	51.83	0.260	51.18	0.254
4	51.00	0.251	53.80	0.248	53.43	0.250	46.80	0.279	52.47	0.256	52.02	0.250
5	50.77	0.252	55.03	0.247	54.63	0.251	46.12	0.274	52.87	0.257	51.85	0.260
6	51.23	0.250	54.13	0.247	53.48	0.250	45.84	0.271	52.27	0.256	52.02	0.266
7	53.80	0.249	53.90	0.247	53.46	0.249	46.09	0.274	52.53	0.255	53.40	0.251
8	53.40	0.248	55.63	0.246	53.40	0.252	46.17	0.277	52.03	0.255	52.12	0.256
9	53.67	0.248	54.33	0.246	53.43	0.250	46.20	0.279	51.47	0.254	53.45	0.248
10	53.33	0.248	54.57	0.247	52.87	0.249	46.91	0.270	51.97	0.260	50.85	0.255
11	53.57	0.249	53.90	0.248	52.83	0.251	46.21	0.281	50.97	0.263	52.05	0.249
12	54.03	0.249	53.97	0.247	52.00	0.250	46.18	0.280	50.87	0.259	51.02	0.274

Tabuľka 6.3: Vplyv počtu sezón na presnosť a Brier skóre pri predikcii udalostí „obaja dajú gól“ (ODG). Pri tejto udalosti je vidieť, že model **Advanced-NNET** bol stále presnejší s narastajúcim počtom historických dát. Avšak len model **Advanced-NNET** zlepšoval svoju presnosť s narastajúcim objemom dát. Na rozdiel od tohto modelu, výkonnosť ostatných modelov nebola závislá od rozsahu historických dát, podobne ako v predchádzajúcich prípadoch.

V tomto experimente boli ako kľúčové metriky zvolené presnosť a Brierovo skóre, čo umožňuje efektívne ilustrovať porovnanie navrhnutých predikčných modelov s výkonnosťou stávkových kancelárií. Z grafov 6.1 je vidieť, že **prekonať presnosť bookmakera je veľmi náročná úloha**, preto bude potrebné zvoliť inú stratégiu, a to **hľadať nekonzistencie v trhu**.

Zaujímavým zistením je, že modely s detailnejšími príznakmi vykazujú vyššiu presnosť oproti modelom, ktoré používajú výhradne základné príznaky. Aj keď sa rozdiel v priemere o 2% môže zdať malý, v kontexte predikcií futbalových udalostí predstavuje tento rozdiel podstatnú výhodu. Na ilustráciu významu tohto zlepšenia: zvýšenie presnosti modelu o ďalšie 2% by nás dostalo na úroveň bookmakera. Tento trend naznačuje, že **vhodne zvolené a relevantné príznaky majú kľúčový vplyv na zlepšenie predikčných schopností modelu**.

Zhrnutie experimentu 1

Aj napriek zaznamenaným malým rozdielom v grafoch, výsledky experimentu neumožnili potvrdiť, alebo vyvrátiť hypotézu o zlepšení presnosti a Brier skóre pri obmedzení datasetu na posledné sezóny. Tieto minimálne rozdiely by mohli byť ovplyvnené obmedzeným počtom testovacích zápasov, ktorý bol stanovený na 2000 a neúplnosťou všetkých príznakov posledných 3 sezón (viz. tabuľka 3.1).


6.2 Analýza vplyvu kurzov na predikčnú efektivitu a ziskovosť modelov

V sekcii 2.5.4 sa diskutuje o hypotéze, že **zahrnutie kurzov do modelu môže zvýšiť jeho predikčnú presnosť**. Avšak, toto **zvýšenie presnosti môže byť na úkor zníženia ziskovosti**, pretože kurzy by mali odrážať pravdepodobnosti udalostí podľa bookmakerov. Ako už bolo


spomenuté v sekcii 2.5.4, bookmakeri používajú stávky, ktoré sú často nastavené ako neférové. Naproti tomu, v sekcii 2.4 sa spomenula štúdia autorov [Rodriguesa a Pinta](#), ktorí efektívne využili kurzy na predpovedanie výsledkov športových udalostí, čím dosiahli výrazný zisk. Tento spor motivuje ďalšiu hypotézu, ktorá sa zameriava na otestovanie využitia kurzov ako predikčného faktora.

V rámci tejto analýzy sa otestujú pokročilé (Advanced) modely definovaných v sekcii 3.4 pričom sa skúma, ako prítomnosť kurzov ovplyvňuje výkonnosť modelov. **Modely budú natréňované v dvoch scenároch. S využitím kurzov ako predikčných príznakov a bez nich.** Cieľom je zistiť, ako sa tieto dva prístupy líšia nielen v presnosti predikcií, ale aj v ich schopnosti generovať zisk.


Pri predikcii udalosti „výsledok zápasu“ je z grafu 6.2 viditeľné, že modely Random Forest a Neurónová sieť boli **účinnnejšie, keď nepoužívali kurzy stávkových kancelárií**, a to po celú dobu predikcie. Naopak, pri modeli XGBoost použitie kurzov zlepšilo jeho schopnosť generovať zisk o viac ako 15%. Ďalej, pri predikcii udalostí „počet gólov viac ako 2.5“ (viz. graf 6.4) a „obaja dajú gól“ (viz. graf 6.5) boli **modely používajúce kurzy stávkových kancelárií menej úspešné** v porovnaní s tými, ktoré ich nepoužívali, na vzorke posledných 2000 zápasov.




Obrázok 6.2: Kumulatívny zisk jednotlivých modelov z predikcií udalosti „výsledok zápasu“ (VYS) za 175 stávkových dní, čo zahŕňa 2000 zápasov. Modely Advanced-RF a Advanced-NNET dosiahli vyšší zisk bez použitia informácií o kurzoch, zatiaľ čo model Advanced-XGB bol ziskovejší s týmito príznakmi. Zaujímavé je, že všetky modely boli ziskové, čo by mohlo byť spôsobené **častejším výskytom pravdepodobnejších udalostí s nižšími kurzami** v danom období. Ak sa modely efektívne naučili predpovedať tieto udalosti, tak to mohlo viesť k ich ziskovosti. Z grafu nemusí byť zrejмый výkonnostný rozdiel medzi modelmi, ktoré využívajú kurzy a tými, ktoré ich nevyužívajú. Pre lepšiu názornosť týchto rozdielov som pripravil graf 6.3 delty ziskov, kde sú tieto rozdiely zreteľnejšie.



Obrázok 6.3: Graf ukazuje vývoj rozdielu ziskov (delta zisk) medzi modelmi, ktoré nevyužívajú kurzy stávkových kancelárií ako príznak, a modelmi, ktoré kurzy používajú. Delta zisk predstavuje rozdiel v ziskoch týchto dvoch skupín modelov za určité časové obdobie. Analýza sa týka udalosti „výsledok zápasu“ (VYS)



Obrázok 6.4: Kumulovaný zisk z predikcií udalosti „počet gólov viac ako 2.5“ (V/M 2.5) zaznamenaný jednotlivými modelmi počas 175 stávkových dní, ktoré zahrňovali 2000 zápasov. Pri tejto udalosti boli ziskovejšie modely bez použitia kurzov stávkových kancelárií, čo naznačuje lepšiu prediktívnu schopnosť pri absencii týchto príznakov. Zaujímavým zistením je, že aj keď v priebehu času dochádzalo k striedaniu výsledkov medzi modelmi, ktoré používali kurzy a tými, ktoré ich nepoužívali, nakoniec sa ukázalo, že modely bez kurzov dosiahli vyšší zisk. Avšak, nie je možné so zaručenou istotou tvrdiť, či by sa v budúcom období výsledky neobrátili. Preto by bolo vhodné tento experiment opakovať s väčším počtom dát a rozšíriť testovaciu sadu, aby boli výsledky spoľahlivejšie.



Obrázok 6.5: Kumulatívny zisk z predikcií udalosti „obaja dajú gól“ (ODG) za obdobie 175 stávkových dní, zahrňujúcich celkovo 2000 zápasov, pre jednotlivé modely. Modely, ktoré nepoužívali kurzy stávkových kancelárií, boli pri tejto udalosti ziskovejšie, čo poukazuje na ich lepšiu prediktívnu schopnosť bez závislosti na týchto príznakoch.

	Neurónová sieť		Random Forest		XGBoost	
Použitie kurzov	Áno	Nie	Áno	Nie	Áno	Nie
Výsledok zápasu						
Presnosť	80.25%	79.46%	80.30%	80.75%	80.10%	79.30%
Presnosť (škálovaná)	50.27%	50.68%	50.63%	50.80%	50.56%	50.18%
Brier skóre	0.1790	0.1865	0.1502	0.1499	0.1627	0.1665
ROI	10.88%	25.28%	30.94%	32.00%	22.48%	7.31%
Podobnosť bookmakera	0.0367	0.0399	0.0024	0.0036	0.0172	0.0182
Počet gólov viac ako 2.5						
Presnosť	60.05%	59.50%	59.15%	59.10%	52.72 %	51.06%
Presnosť (škálovaná)	50.02%	50.70%	50.33%	50.86%	47.53%	49.31%
Brier skóre	0.2498	0.2518	0.2366	0.2383	0.2507	0.2510
ROI	0.710%	28.09%	13.28%	34.34%	-65.39%	-16.94%
Podobnosť bookmakera	0.0242	0.0275	0.0024	0.0046	0.0124	0.0129
Obaja dajú gól						
Presnosť	46.15%	55.95%	56.00%	52.60%	49.20%	53.65%
Presnosť (škálovaná)	48.26%	50.27%	49.47%	49.93%	47.89%	48.91%
Brier skóre	0.2442	0.2467	0.2444	0.2504	0.2522	0.2487
ROI	-69.60%	10.07%	-21.16%	-2.630%	-84.53%	-43.48%
Podobnosť bookmakera	0.0024	0.0039	0.0028	0.0069	0.0089	0.0077

Tabuľka 6.4: Experimentálne výsledky modelov s použitím a bez použitia kurzov stávkových kancelárií. V tabuľke sú hodnotené metriky klasická a škálovaná presnosť, Brier skóre, ROI a podobnosť s predikciami bookmakera. Aby bolo jasne rozpoznatelné, ktorý model bol najlepší pre konkrétnu udalosť a metriku, vyznačil som najlepšie hodnoty rôznymi farbami. Toto farebné rozlíšenie umožňuje jednoduchšie vizuálne porovnanie výkonu modelov.


Vo väčšine analyzovaných prípadov sa potvrdilo, že kurzové ponuky stávkových kancelárií, braných ako príznak, majú negatívny vplyv na návratnosť investície (ROI). Z metríky podobnosti s bookmakerom je zrejmé, že modely využívajúce kurzy vykazujú vyššiu koreláciu s predpoveďami stávkových kancelárií, čo je v súlade s pôvodnými očakávaniami.

Zhrnutie experimentu 2


Tento experiment ilustruje, že hoci vplyv používania kurzov ako prediktívnych príznakov v priemere zhoršuje ziskovosť modelu, existujú výnimky, kde môže byť prístup efektívnejší. Príkladom je model XGBoost pri predikcii udalosti „výsledok zápasu“, kde prítomnosť kurzov znamenala výrazné zlepšenie výkonu. Tento nález poukazuje na potrebu flexibilného prístupu pri vývoji takýchto modelov, keďže niektoré techniky môžu profitovať z určitých typov dát viac ako iné.

6.3 Vyhodnotenie predikčných modelov


V tejto časti sú prezentované výsledky jednotlivých modelov oproti základným modelom. Nasledujúci experiment ukazuje porovnanie medzi pokročilými (Advanced) modelmi, jednoduchými (Simple) modelmi a základnými modelmi (viz. sekcia 3.4), ako je náhodný model (Random) a model predikujúci väčšinovú triedu (Naive). Tieto základné modely poskytujú referenčný bod pre hodnotenie implementovaných riešení a pomáhajú lepšie pochopiť dynamiku hry, čím umožňujú detailnejšie porovnanie výkonnosti modelov.




Obrázok 6.6: **Kumulatívny zisk** predikcie udalosti „výsledok zápasu“ (VYS) pre jednotlivé modely počas 175 stávkových dní, ktoré pokrývajú 2000 zápasov. Väčšina modelov výrazne prekonala základné modely, ktoré by pravdepodobne skončili v bankrote. Najlepšie výsledky ukázali komplexnejšie (Advanced) modely s detailnejšími príznakmi, najmä model Random Forest a neurónová sieť. Model **Advanced-RF** dosiahol najvyšší zisk 32.01%.




Obrázok 6.7: Graf zobrazuje trend kumulatívneho zisku pri predikcii udalosti „výsledok zápasu“ (VYS) za stávkové dni pomocou lineárnej interpolácie. Analýza prebieha počas 175-dňového obdobia a zahŕňa všetky mnou definované modely. Lineárna interpolácia ukazuje všeobecný trend zisku alebo strát pre každý model, čo umožňuje rýchle porovnanie ich efektívnosti v čase.




Obrázok 6.8: **Kumulatívny zisk** predikcie udalosti „počet gólov viac ako 2.5“ (V/M 2.5) pre jednotlivé modely počas 175 stávkových dní zahrňujúcich 2000 zápasov. Naivný model, ktorý konzistentne predikoval väčšinovú triedu, sa ukázal byť v tomto časovom horizonte ziskový (po dlhšom čase by ale určite skončil v bankrote), čo naznačuje, že modely, ktoré boli ziskové, ale neprekonal tento jednoduchý model, tak si pravdepodobne neosvojili ani základnú stratégiu predikcie. Najúspešnejšie výsledky predviedli pokročilé (Advanced) modely neurónová sieť a Random Forest. Neurónová sieť, dosiahla zaujímavý zisk 34.9%.



Obrázok 6.9: Graf zobrazuje trend kumulatívneho zisku pri predikcii udalosti „počet gólov viac ako 2.5“ (V/M 2.5) za stávkové dni získaný pomocou lineárnej interpolácie. Analýza prebieha počas 175-dňového obdobia a zahŕňa všetky mnou definované modely. Lineárna interpolácia ukazuje všeobecný trend zisku alebo strát pre každý model, čo umožňuje rýchle porovnanie ich efektívnosti v čase.



Obrázok 6.10: **Kumulatívny zisk** predikcie udalosti „obaja dajú gól“ (ODG) pre jednotlivé modely počas 175 stávkových dní, zahrňujúci 2000 zápasov. Pri tejto udalosti dominovali modely neurónovej siete a Random Forest. Zaujímavosťou je, že model Random Forest dosiahol lepšie výsledky s jednoduchými príznakmi ako s detailnejšími. Najvyšší zisk 20.42% zaznamenal model **Advanced-NNET**. Naopak, model XGBoost, použitý pri tomto type predikcie, vykazoval výsledky zrovnateľné s naivným modelom, čo poukazuje na jeho obmedzenia v určitých špecifických scenároch.



Obrázok 6.11: Graf zobrazuje trend kumulatívneho zisku pri predikcii udalosti „oba tímy dajú gól“ (ODG) za stávkové dni získaný pomocou lineárnej interpolácie. Analýza prebieha počas 175-dňového obdobia a zahŕňa všetky mnou definované modely. Lineárna interpolácia ukazuje všeobecný trend zisku alebo strát pre každý model, čo umožňuje rýchle porovnanie ich efektívnosti v čase.

XGBoost modely

V tejto časti sa venujem analýze výsledkov modelov XGBoost. Pri porovnaní so základnými modelmi sa ukázalo, že výkon modelov XGBoost nie je veľmi efektívny. Model XGBoost sa osvedčil len v jednom prípade: pri predikcii udalosti „výsledok zápasu“ (VYS), kde dosiahol model **Advanced-XGB** zisk **11.21%**. V ostatných prípadoch modely neboli ziskové, alebo neprekonali naivný model. Jednoduchšia (Simple) verzia modelu bola efektívnejšia len pri udalosti „počet gólov viac ako 2.5“ (V/M 2.5), čo vzhľadom na množstvo testovacích dát môže byť považované za úroveň štatistickej chyby. Vo všeobecnosti by som tento model pre túto úlohu neodporúčal, pretože jeho výsledky sú nestabilné a vykazujú vysokú volatilitu.

Random Forest modely

Pokročilý model Random Forest bol výnimočne úspešný pri predikcii udalostí „výsledok zápasu“ (VYS) a „počet gólov viac ako 2.5“ (V/M 2.5), kde dosiahol zisk **32.01%** a **34.34%**. Naproti tomu, pri udalosti „obaja dajú gól“ (ODG) boli lepšie výsledky zaznamenané pri modely so základnými príznakmi, zatiaľ čo komplexnejšia verzia vykázala miernu stratu. Celkovo tento model demonštruje vysoký potenciál, vďaka svojej **schopnosti efektívne spracovávať veľké množstvo príznakov**, kedy spolu s mechanizmom náhodného výberu prvkov a stromov, tento model lepšie generalizuje a je **menej náchylný k preučeniu**, čím sa vyhýba problémom s pretrénovaním a zabezpečuje robustné výsledky.

Modely neurónovej siete

Model neurónovej siete bol úspešný pri predikcii všetkých troch udalostí, pričom v každom prípade dosiahol solídny zisk. Pri udalosti „výsledok zápasu“ (VYS) zaznamenal zisk **22.57%**, pri „počet gólov viac ako 2.5“ (V/M 2.5) to bolo **34.9%** a pri „obaja dajú gól“ (ODG) **20.42%**. V každej z týchto udalostí bol model efektívnejší s použitím detailných príznakov. Úspech modelu neurónovej siete v rôznych predikčných scenároch je prekvapivý a naznačuje jeho potenciál ako **najvhodnejšieho riešenia** pre tento typ problému, dokonca aj pri relatívne obmedzenom množstve dát.

	Presnosť	Presnosť (škálovaná)	Brier skóre	ROI
Výsledok zápasu				
Advanced-NNET	79.27%	50.44%	0.1655	22.57%
Simple-NNET	69.37%	49.85%	0.2666	-5.33%
Advanced-RF	80.75%	50.80%	0.1499	32.01%
Simple-RF	63.11%	49.19%	0.2374	-14.70%
Advanced-XGB	76.31%	50.36%	0.1879	11.21%
Simple-XGB	64.56%	48.45%	0.2476	-39.18%
Naive	70.70%	49.10%	0.2930	-36.02%
Random	50.80%	47.21%	0.4920	-111.66%
Počet gólov viac ako 2.5				
Advanced-NNET	59.68%	50.95%	0.2533	34.90%
Simple-NNET	43.28%	45.02%	0.2972	-194.08%
Advanced-RF	59.10%	50.86%	0.2383	34.34%
Simple-RF	56.45%	49.86%	0.2435	-5.43%
Advanced-XGB	56.20%	49.69%	0.2439	-12.51%
Simple-XGB	55.25%	50.24%	0.2469	9.76%
Naive	56.00%	50.48%	0.4400	19.19%
Random	48.75%	46.85%	0.5140	-126.05%
Obaja dajú gól				
Advanced-NNET	50.31%	51.56%	0.2501	20.42%
Simple-NNET	45.70%	48.52%	0.2803	-22.40%
Advanced-RF	55.85%	49.92%	0.2464	-3.26%
Simple-RF	55.00%	50.29%	0.2484	11.40%
Advanced-XGB	51.77%	49.81%	0.2521	-4.46%
Simple-XGB	53.35%	49.05%	0.2501	-37.87%
Naive	54.40%	49.07%	0.2498	-35.99%
Random	47.85%	45.93%	0.2564	-162.93%

Tabuľka 6.5: Experimentálne výsledky výkonnosti jednotlivých modelov v porovnaní so základnými modelmi. V tabuľke sú hodnotené metriky ako klasická a škálovaná presnosť, Brier skóre a návratnosť investície (ROI). Táto komplexná analýza poskytuje hĺbkové porovnanie medzi modelmi a identifikuje ich silné a slabé stránky v kontexte ich aplikácie.

Zhrnutie

Kvôli náročnosti tréovania jednotlivých modelov som sa rozhodol **vybrať 4 najziskovejšie a natrénovať ich 10krát s rôznou inicializáciou váh**, aby sa zistilo, či výsledky nie sú len náhoda dobré nainicializovaných počiatočných váh. Sú to tieto modely:

- **Advanced-RF-VYS** - Pokročilý model Random Forest predikujúci udalosť „výsledok zápasu“
- **Advanced-RF-V/M-2.5** - Pokročilý model Random Forest predikujúci udalosť „počet gólov viac ako 2.5“
- **Advanced-NNET-V/M-2.5** - Pokročilý model neurónovej siete predikujúci udalosť „počet gólov viac ako 2.5“
- **Advanced-NNET-ODG** - Pokročilý model neurónovej siete predikujúci udalosť „obaja dajú gól“


Na základe týchto behov sa vypočíta priemerná stredná hodnota a variancia preškalovanej presnosti aby som vedel s lepšou istotou zhodnotiť a utvrdiť výsledky jednotlivých modelov. Z grafu 6.12 je zrejmé, že model **Advanced-RF-VYS** dosiahol priemernú návratnosť investície (ROI) 32.38%, **Advanced-RF-V/M-2.5** dosiahol 29.04%, a **Advanced-NNET-V/M-2.5** dosiahol 24.61%. Naopak, model **Advanced-NNET-ODG** vykázal stratu -7.92%, čo naznačuje, že jeho počiatočné úspechy boli pravdepodobne spôsobené dobre nastavenými váhami, keďže v ďalších behoch jeho ziskovosť rapidne klesla. Ďalšie detaily sú uvedené v tabuľke 6.6.

Je dôležité zdôrazniť, že zisk vo väčšine prípadov fluktoval, čo znamená, že nie je možné s istotou tvrdiť, že modely, ktoré momentálne vykazujú zisk, nebudú v budúcnosti strácať. Napriek tomu sú výsledky veľmi sľubné, no je **potrebné uskutočniť dôkladnejšie testovanie na rozšírenejšom datasete**. To by znamenalo **zahrnutie viacerých líg a sezón** do datasetu. Tieto pozitívne výsledky však otvárajú priestor pre ďalšie vylepšenia tohto modelu.

Na záver som svoje výsledky porovnal s výsledkami uvedenými v štúdiách z úvodnej časti. Z tabuľky 6.7 je vidieť, že moje výsledky prekonal tie zo spomenutých prác. Ako som už spomínal, hoci výsledky vyzerajú veľmi sľubne, je nevyhnutné ich ešte podrobne overiť na väčšom objeme testovacích dát.

	Udalosť	Stredná hodnota	Smerodajná odchýlka	Rozptyl	Max	Min
Advanced-RF	VYS	50.7658	0.00113	1.2778×10^{-6}	50.9645	50.6260
Advanced-RF	V/M 2.5	50.7260	0.00327	1.0704×10^{-5}	51.0027	50.6307
Advanced-NNET	V/M 2.5	50.6153	0.00155	2.4073×10^{-6}	50.8620	50.4430
Advanced-NNET	ODG	49.5170	0.00299	8.9861×10^{-6}	49.8866	49.0586

Tabuľka 6.6: Experimentálne výsledky desiatich behov so 4 najlepšimi modelmi, pričom každý beh začínal s náhodnou inicializáciou váh. Jednotlivé hodnoty sa vzťahujú na metriku **preškalovaná presnosť** (viz. sekcia 5.1.1).



Obrázok 6.12: Kumulatívny zisk a jeho trend z predikcií 4 najlepších modelov za 175 stávkových dní obsahujúcich 2000 zápasov. Tieto modely boli natrénované desaťkrát s rôznymi inicializáciami váh, aby sa overilo, či výsledky nezávisia len od vhodnej inicializácie. Výsledné hodnoty (vrátane ROI) boli následne **spriemerované**.

Model	Typ výstupu	Udalosť	Presnosť	ROI	Štúdia
Modely overené v štúdiách					
Neurónová sieť	Double poisson	V/M 2.5	56.55%	-7.1%	[34]
Neurónová sieť	Double poisson	ODG	53.89%	-6.8%	[34]
Neurónová sieť	Double poisson	VYS	50.78%	-7.2%	[34]
Neurónová sieť	Pravdepodobnosť triedy	V/M 2.5	59.13%	16,54%	[3]
XGBoost	Pravdepodobnosť triedy	VYS	63.95%	19.7%	[27]
SVM	Pravdepodobnosť triedy	VYS	61.32%	12.5%	[18]
Random Forest	Pravdepodobnosť triedy	VYS	59.21%	11.11%	[27]
Modely implementované v tejto štúdii					
Advanced-RF	Pravdepodobnosť triedy	VYS	76.41%	32.38%	-
Advanced-RF	Pravdepodobnosť triedy	V/M 2.5	59.1%	29.04%	-
Advanced-NNET	Pravdepodobnosť triedy	V/M 2.5	59.68%	24.61%	-

Tabuľka 6.7: Porovnanie výkonnosti a ziskovosti jednotlivých modelov zahrnutých v úvodných štúdiách a novo implementovaných v rámci tejto práce.

Kapitola 7

Záver

Cieľom tejto práce bolo porovnať rôzne modelovacie prístupy súvisiace s futbalovými udalosťami. Vybrali sa modely Random Forest, XGBoost a neurónová sieť, ktorých efektivitu potvrdilo viacero štúdií spomenutých v tejto práci.

Prvá hypotéza, že historické dáta ovplyvňujú výsledky predikcie, sa v žiadnych okolnostiach nepotvrdila. Pre rôzne modely a udalosti bol optimálny počet sezón v datasete rôzny a nedal sa zovšeobecniť. Použitie veľmi malého počtu sezón, ako sú dve alebo tri, viedlo k extrémne malému datasetu, ktorý sa správal chaoticky, čo bolo pravdepodobne spôsobené nedotréňovaním modelu.

Ďalším cieľom práce bolo skúmať vhodnosť použitia kurzov ako príznakov v modeloch. Výsledky ukázali, že takmer všetky modely boli efektívnejšie, keď nevyužívali kurzy ako príznaky. Výnimku tvoril model XGBoost pri predikcii udalosti „výsledok zápasu“, ktorý bol úspešnejší ako model bez kurzov. Tento výsledok mohol byť ovplyvnený inicializáciou váh alebo nedostatočnou veľkosťou dát na testovanie.

Ďalší cieľ tejto práce bol overiť hypotézu o užitočnosti detailných štatistík pri predpovedaní udalostí. Experimentálne sa modely rozdelili do dvoch kategórií: jednoduché (Simple) a pokročilé (Advanced). Jednoduché modely pracovali s obmedzenými príznakmi ako identifikátory tímov, dátum zápasu a priemerný počet gólov, zatiaľ čo pokročilé modely využívali rozšírené štatistiky pre každý tím. V experimentoch pokročilé modely konzistentne prekonávali tie jednoduché, čo naznačuje, že podrobné štatistiky majú významný potenciál pre efektívne modelovanie futbalových udalostí.

Modely boli tiež hodnotené na základe stávkového trhu. Pokročilé modely Random Forest a neurónová sieť ukázali ziskovosť počas jednej sezóny na udalostiach „výsledok zápasu“ a „počet gólov viac ako 2.5“. Model Random Forest na udalosti „výsledok zápasu“ dosiahol ziskovosť **32.38%**. Na udalosti „počet gólov viac ako 2.5“ dosiahol ziskovosť **29.04%** a neurónová sieť tam dosiahla tak isto pôsobivú ziskovosť **24.61%**. Hoci sú na správne zhodnotenie potenciálu modelu potrebné ďalšie testovacie dáta a overenie v praxi, predbežné výsledky naznačujú veľký potenciál týchto modelov.

7.1 Budúci vývoj

Na základe výsledkov tejto práce sa otvárajú možnosti pre budúce výskumy. Hoci som sa v tejto práci obmedzil len na malú podmnožinu možných prístupov, tak je tu možnosť, že ďalšie prístupy by mohli byť efektívnejšie.

Jedno z možných zlepšení by mohlo spočívat v agregácii viacerých metrík do jedinej, čo by mohlo zjednodušiť model a zlepšiť predikcie. Vzhľadom na veľké množstvo príznakov, ktoré môžu niektoré modely preťažiť, by syntéza metrík do jednej kľúčovej metriky mohla viesť k efektívnejšiemu a jasnejšiemu modelovaniu.

Ako ďalšie vylepšenie by som odporučil použitie veľkých jazykových modelov (LLM) na spracovanie obsahu zo sociálnych sietí. Tieto modely by mohli z príspevkov extrahovať užitočné informácie o hráčoch, tréneroch, tímoch, fanúšikovskej nálade a užívateľských predikciách, ktoré by sa potom mohli kombinovať so štatistickými metódami pre lepšie predpovede.

V rámci budúceho vývoja plánujem implementovať špecifickú stratégiu zameranú na zvyšovanie ziskovosti predpovedí. Jedným z kľúčových krokov bude vytvorenie vlastnej **loss funkcie**, ktorá bude priamo motivovať model k maximálnym ziskom. Funkcia bude definovaná nasledovne:

$$L(y_{\text{true}}, y_{\text{pred}}, \mathbf{O}) = -\frac{1}{n} \sum_{i=1}^n \pi(y_{\text{true}, i}, y_{\text{pred}, i}, o_i) \quad (7.1)$$

kde y_{true} sú skutočné výsledky, y_{pred} sú predpovedané pravdepodobnosti výsledkov, $\mathbf{O}$ sú kurzové stávky priradené k jednotlivým výsledkom a π je funkcia na výpočet potenciálneho zisku. Funkcia π môže byť definovaná tak, aby reflektovala rozdiel medzi očakávanou a skutočnou výhrou založenou na kurze, napríklad:

$$\pi(y_{\text{true}, i}, y_{\text{pred}, i}, o_i) = \begin{cases} o_i \cdot \text{vklad} & \text{ak } y_{\text{true}, i} = y_{\text{pred}, i} \\ -\text{vklad} & \text{ak } y_{\text{true}, i} \neq y_{\text{pred}, i} \end{cases} \quad (7.2)$$

Tento prístup umožňuje modelu učiť sa z dát s prihliadnutím na finančnú hodnotu každej predpovede, čo by mohlo viesť k efektívnejšiemu a ziskovejšiemu modelu.

1. Data pro tři zápasy:

• Zápas 1:

- Skutečný výsledek ($y_{\text{true},1}$): výhra domáceho tímu
- Predikovaný výsledek ($y_{\text{pred},1}$): výhra domáceho tímu
- Kurz (o_1): 2.0
- Vklad: 100 Kč

• Zápas 2:

- Skutečný výsledek ($y_{\text{true},2}$): remíza
- Predikovaný výsledek ($y_{\text{pred},2}$): výhra domáceho tímu
- Kurz (o_2): 3.0
- Vklad: 100 Kč

• Zápas 3:

- Skutečný výsledek ($y_{\text{true},3}$): prehra domáceho tímu
- Predikovaný výsledek ($y_{\text{pred},3}$): prehra domáceho tímu
- Kurz (o_3): 1.5
- Vklad: 100 Kč

2. Výpočet funkce π pro každý zápas:

- Zápas 1: $y_{\text{true},1} = y_{\text{pred},1}$, takže $\pi = o_1 \cdot \text{vklad} = 2.0 \cdot 100 = 200$
- Zápas 2: $y_{\text{true},2} \neq y_{\text{pred},2}$, takže $\pi = -\text{vklad} = -100$
- Zápas 3: $y_{\text{true},3} = y_{\text{pred},3}$, takže $\pi = o_3 \cdot \text{vklad} = 1.5 \cdot 100 = 150$

3. Výpočet loss funkce:

$$L = -\frac{1}{3} (200 + (-100) + 150) = -\frac{1}{3} (250) = -\frac{250}{3} \approx -83.33$$

Interpretace výsledku

- Hodnota loss funkce $L \approx -83.33$:

- Negativní hodnota loss funkce je zamýšlená, protože model se optimalizuje k minimalizaci loss funkce, což zde znamená maximalizaci zisku.
- Nižší (méně negativní) hodnota loss funkce naznačuje lepší výkon modelu z hlediska ziskovosti.

Pokud máte model s výstupem pravděpodobností a používáte loss funkci zaměřenou na maximalizaci zisku, interpretace výstupů modelu (pravděpodobnosti) může být trochu odlišná od standardní interpretace pravděpodobností. Zde je, jak můžete interpretovat pravděpodobnosti v kontextu sázkového modelu:

Interpretace pravděpodobností

1. Výstup modelu (např. 0.6):

- Tento výstup znamená, že model predikuje 60% pravděpodobnost, že tým vyhraje daný zápas.

2. Rozhodnutí o sázce:

- Pokud model predikuje 60% pravděpodobnost výhry týmu a kurz na tuto událost je například 2.0, můžete vypočítat očekávaný zisk z této sázky.

Výpočet očekávaného zisku

Vzorec pro očekávaný zisk $E[Z]$ byl uveden takto:

$$E[Z] = (p_n \cdot (o_n - 1)) - (1 - p_n)$$

3. Celkový očekávaný zisk:

$$E[Z] = 0.6 - 0.4 = 0.2$$

Interpretace výsledku

- $E[Z] = 0.2$:
 - Tento výsledek znamená, že očekávaný zisk z jednotkové sázky na výhru týmu je 0.2 jednotky (např. 0.2 Kč).
 - Pozitivní očekávaný zisk znamená, že sázení na tuto událost by mělo být dlouhodobě ziskové.

Predikovaná pravděpodobnost (např. 0.6) znamená, že model odhaduje 60% pravděpodobnost, že tým vyhraje.

Pro rozhodnutí o sázce je důležité porovnat tuto pravděpodobnost s kurzem a vypočítat očekávaný zisk $E[Z]$.

Pozitivní očekávaný zisk znamená, že sázení na tuto událost je pravděpodobně ziskové.

Literatúra

- [1] ARABZAD, S. M., TAYEBI ARAGHI, M., SOHEIL, S.-N. a GHOFRANI, N. Football Match Results Prediction Using Artificial Neural Networks; The Case of Iran Pro League. *International Journal of Applied Research on Industrial Engineering*. Október 2014, zv. 1, s. 159–179.
- [2] BRECHOT, M. a FLEPP, R. Dealing with randomness in match outcomes: how to rethink performance evaluation and decision-making in European club football. UZH Business Working Paper Series. 2018.
- [3] CARLONI, L., DE ANGELIS, A., SANSONETTI, G. a MICARELLI, A. A Machine Learning Approach to Football Match Result Prediction. In: Júl 2021, s. 473–480. ISBN 978-3-030-78641-0.
- [4] CARRON, A. a PARADIS, K. The Home Advantage. In: Január 2014, s. 351–355. DOI: 10.4135/9781483332222.n138. ISBN Print: 9781452203836 Online: 9781483332222.
- [5] CHEN, T. a GUESTRIN, C. XGBoost: A Scalable Tree Boosting System. In: New York, NY, USA: Association for Computing Machinery, 2016, s. 785–794. KDD '16. DOI: 10.1145/2939672.2939785. ISBN 9781450342322. Dostupné z: <https://doi.org/10.1145/2939672.2939785>.
- [6] DIXON, M. J. a COLES, S. G. Modelling Association Football Scores and Inefficiencies in the Football Betting Market. *Journal of the Royal Statistical Society*. Oxford, UK and Boston, USA: Blackwell Publishers Ltd. 1997, zv. 46, č. 2, s. 265–280. ISSN 0035-9254.
- [7] ELMILIGI, H. a SAAD, S. Predicting the Outcome of Soccer Matches Using Machine Learning and Statistical Analysis. In: *2022 IEEE 12th Annual Computing and Communication Workshop and Conference (CCWC)*. 2022, s. 1–8. DOI: 10.1109/CCWC54503.2022.9720896.
- [8] ERYARSOY, E. a DELEN, D. Predicting the Outcome of a Football Game: A Comparative Analysis of Single and Ensemble Analytics Methods. In: Január 2019. DOI: 10.24251/HICSS.2019.136.
- [9] FORREST, D., GODDARD, J. a SIMMONS, R. Odds-setters as forecasters: The case of English football. *International Journal of Forecasting*. 2005, zv. 21, č. 3, s. 551–564. DOI: <https://doi.org/10.1016/j.ijforecast.2005.03.003>. ISSN 0169-2070. Dostupné z: <https://www.sciencedirect.com/science/article/pii/S0169207005000300>.

- [10] GHIMIRE, P. *Sofifa-web-scraper* [<https://github.com/prashantghimire>]. 2024. Available online at <https://github.com/prashantghimire/sofifa-web-scraper>.
- [11] GODIN, F., ZUALLAERT, J., VANDERSMISSEN, B., DE NEVE, W. a WALLE, R. Van de. Beating the bookmakers: leveraging statistics and Twitter microposts for predicting soccer results. In: ACM New York, NY, USA. *KDD Workshop on large-scale sports analytics*. 2014, s. 2–14.
- [12] HERBINET, C. *Predicting Football Results Using Machine Learning Techniques* [online]. 2018 [cit. 2023-10-02]. Dostupné z: <https://www.imperial.ac.uk/media/imperial-college/faculty-of-engineering/computing/public/1718-ug-projects/Corentin-Herbinet-Using-Machine-Learning-techniques-to-predict-the-outcome-of-professional-football-matches.pdf>.
- [13] HUBÁČEK, O., ŠOUREK, G. a ŽELEZNÝ, F. Exploiting sports-betting market using machine learning. *International Journal of Forecasting*. 2019, zv. 35, č. 2, s. 783–796. DOI: <https://doi.org/10.1016/j.ijforecast.2019.01.001>. ISSN 0169-2070. Dostupné z: <https://www.sciencedirect.com/science/article/pii/S016920701930007X>.
- [14] HUBÁČEK, O., ŠÍR, G. a ŽELEZNÝ, F. Learning to predict soccer results from relational data with gradient boosted trees. *Machine Learning*. Január 2019, zv. 108. DOI: 10.1007/s10994-018-5704-6.
- [15] HUCALJUK, J. a RAKIPOVIĆ, A. Predicting football scores using machine learning techniques. In: *2011 Proceedings of the 34th International Convention MIPRO*. 2011, s. 1623–1627.
- [16] HVATTUM, L. M. a ARNTZEN, H. Using ELO ratings for match result prediction in association football. *International Journal of Forecasting*. 2010, zv. 26, č. 3, s. 460–470. DOI: <https://doi.org/10.1016/j.ijforecast.2009.10.002>. ISSN 0169-2070. Sports Forecasting. Dostupné z: <https://www.sciencedirect.com/science/article/pii/S0169207009001708>.
- [17] INAN, T. Using Poisson model for goal prediction in European football. *Journal of human sport and exercise*. University of Alicante. 2021, zv. 16, č. 4, s. 942–955. ISSN 1988-5202.
- [18] KECMAN, V. Support Vector Machines – An Introduction. In: WANG, L., ed. 2005, s. 1–47. ISBN 978-3-540-32384-6.
- [19] KOEHRSEN, W. *The Poisson Process and Poisson Distribution, Explained* [online]. [cit. 2024-1-28]. Dostupné z: <https://builtin.com/data-science/poisson-process>.
- [20] KUMAR, G. Machine learning for soccer analytics. *University of Leuven*. 2013.
- [21] LOEFFELHOLZ, B., BEDNAR, E. a BAUER, K. Predicting NBA Games Using Neural Networks. *Journal of Quantitative Analysis in Sports*. Február 2009, zv. 5, s. 7–7. DOI: 10.2202/1559-0410.1156.
- [22] MAHER, M. J. Modelling association football scores. *Statistica Neerlandica*. 1982, zv. 36, č. 3, s. 109–118. DOI: <https://doi.org/10.1111/j.1467-9574.1982.tb00782.x>. Dostupné z: <https://onlinelibrary.wiley.com/doi/abs/10.1111/j.1467-9574.1982.tb00782.x>.

- [23] MILJKOVIĆ, D., GAJIĆ, L., KOVAČEVIĆ, A. a KONJOVIĆ, Z. The use of data mining for basketball matches outcomes prediction. In: *IEEE 8th International Symposium on Intelligent Systems and Informatics*. 2010, s. 309–312. DOI: 10.1109/SISY.2010.5647440.
- [24] NAM, E. *Understanding the Levenshtein Distance Equation for Beginners* [online]. [cit. 2023-11-21]. Dostupné z: <https://medium.com/@ethannam/understanding-the-levenshtein-distance-equation-for-beginners-c4285a5604f0>.
- [25] NATEKIN, A. a KNOLL, A. Gradient boosting machines, a tutorial. *Frontiers in neurorobotics*. 2013, zv. 7, s. 21. DOI: 10.3389/fnbot.2013.00021. ISSN 1662-5218.
- [26] ROBBERECHTS, P. a DAVIS, J. How Data Availability Affects the Ability to Learn Good xG Models. In: *Machine Learning and Data Mining for Sports Analytics*. Cham: Springer International Publishing, 2020, s. 17–27. ISBN 978-3-030-64912-8.
- [27] RODRIGUES, F. a PINTO Ângelo. Prediction of football match results with Machine Learning. *Procedia Computer Science*. 2022, zv. 204, s. 463–470. DOI: <https://doi.org/10.1016/j.procs.2022.08.057>. ISSN 1877-0509. International Conference on Industry Sciences and Computer Science Innovation. Dostupné z: <https://www.sciencedirect.com/science/article/pii/S1877050922007955>.
- [28] SARAIVA, E., SUZUKI, A., FILHO, C. a LOUZADA, F. Predicting football scores via Poisson regression model: applications to the National Football League. *Communications for Statistical Applications and Methods*. Júl 2016, zv. 23, s. 297–319. DOI: 10.5351/CSAM.2016.23.4.297.
- [29] SCHMIDT, I. G. *Fitting your own football xG model* [online]. [cit. 2023-10-17]. Dostupné z: <https://www.datofutbol.cl/blog/xg-model/>.
- [30] SKIERA, B. a SPANN, M. Sports Forecasting: A Comparison of the Forecast Accuracy of Prediction Markets, Betting Odds and Tipsters. *Journal of Forecasting*. Január 2009, zv. 28, s. 55–72. DOI: 10.1002/for.1091.
- [31] SOKOLOVA, M., JAPKOWICZ, N. a SZPAKOWICZ, S. Beyond Accuracy, F-Score and ROC: A Family of Discriminant Measures for Performance Evaluation. In: Január 2006, Vol. 4304, s. 1015–1021. ISBN 978-3-540-49787-5.
- [32] TALWALKER, S. A Characterization of the Double Poisson Distribution. 1970, zv. 32, s. 265–270. ISSN 0581572X. Dostupné z: <http://www.jstor.org/stable/25049667>.
- [33] TAX, N. a JOUSTRA, Y. Predicting the Dutch football competition using public data: A machine learning approach. *Transactions on knowledge and data engineering*. 2015, zv. 10, č. 10, s. 1–13.
- [34] VAKNIN, E. *Predicting Score-related Events in Soccer*. Brno, CZ, 2021. Diplomová práce. České Vysoké učení technické v Brně, Fakulta informačních technologií. Dostupné z: <https://dspace.cvut.cz/bitstream/handle/10467/95294/F3-DP-2021-Vaknin-Erik-Predicting-Score-Related-Events-in-Soccer.pdf?isAllowed=y&sequence=-1>.

- [35] ZHANG, Q., ZHANG, X., HU, H., LI, C., LIN, Y. et al. Sports match prediction model for training and exercise using attention-based LSTM network. *Digital Communications and Networks*. 2022, zv. 8, č. 4, s. 508–515. DOI: <https://doi.org/10.1016/j.dcan.2021.08.008>. ISSN 2352-8648. Dostupné z: <https://www.sciencedirect.com/science/article/pii/S2352864821000602>.

Príloha A

Matica štatistík hráčov

Príznak	Hráč 1	Hráč 2	Hráč n	Hráč 29	Hráč 30
Celkové hodnotenie	75	88	82	79	85
Potenciálne hodnotenie	80	90	85	81	87
Centrovanie	65	77	70	68	74
Zakončenie	78	84	80	76	82
Presnosť hlavičkovania	70	75	72	69	73
Krátke prihrávky	85	89	87	83	88
Voleje	77	80	78	76	79
Dribling	82	90	86	84	89
Krivka kopu	69	73	71	70	74
Presnosť priamych kopov	65	78	72	67	76
Dlhé prihrávky	82	85	83	80	84
Kontrola lopty	88	92	90	86	91
Zrýchlenie	90	93	91	89	94
Rýchlosť šprintu	89	94	90	87	93
Obratnosť	84	87	85	82	86
Reakcie	78	82	80	77	81
Rovnováha	73	76	74	72	75
Sila strely	85	90	87	83	89
Skok	77	80	78	75	79
Výdrž	92	95	93	90	94
Sila	83	88	85	81	86
Strely z diaľky	75	80	77	73	78
Agresivita	68	72	70	67	71
Zákroky	82	85	83	80	84
Penalty	79	83	81	78	82
Vyrovnanosť	81	84	82	79	83
Obranné povedomie	88	91	89	85	90
Zákrok v stoji	90	93	91	87	92
Sklzový zákrok	85	88	86	82	87
Brankárske skoky	70	75	72	68	73
Kopanie brankára	78	82	79	76	81
Reflexy brankára	88	92	90	86	91

Tabuľka A.1: Matica štatistík hráčov (transponovaná, kvôli kompaktnosti) slúži ako vstup pre konvolučnú neurónovú sieť. Rozsah týchto hodnôt môže byť od 0 do 99.

Príloha B

Tabuľka príznakov na úrovni tímov

Príznak	Hráč 1
result_1_pst	Štatistiky hráčov transformované tak, aby odrážali výsledok zápasu (výhra domácich)
result_X2_pst	Štatistiky hráčov transformované tak, aby odrážali výsledok zápasu (host neprehrá)
result_1X_pst	Štatistiky hráčov transformované tak, aby odrážali výsledok zápasu (domáci neprehrá)
result_2_pst	Štatistiky hráčov transformované tak, aby odrážali výsledok zápasu (výhra hostí)
lt_diff_xG_ma_g	Dlhodobý kľzavý priemer rozdielu očakávaných gólov na zápas
lt_diff_goals_ma_g	Dlhodobý kľzavý priemer rozdielu strelených gólov na zápas
ht_elo	hodnotenie Elo domáceho tímu
at_elo	hodnotenie Elo hostujúceho tímu
st_diff_goals_ma_g	Krátkodobý kľzavý priemer gólového rozdielu na zápas
ht_win_rate	Celková úspešnosť domáceho tímu
lt_diff_goals_ma_c	Dlhodobý kľzavý priemer rozdielu inkasovaných gólov na zápas
ht_h2h_at_blocked_shots	Kľzavý priemer zablokovaných striel domáceho tímu v head-to-head zápasoch na ihrisku hostí
ath_h2h_shots_outsidebox	Kľzavý priemer celkového počtu striel mimo šestnástky hostí v head-to-head súbojoch
at_h2h_ht_shots_outsidebox	Kľzavý priemer striel hostí mimo šestnástky v head-to-head súbojoch na domácom ihrisku
ath_h2h_diff_shots_outsidebox	Kľzavý priemer rozdielu v počte striel hostí mimo hracej plochy v head-to-head súbojoch
ht_h2h_at_ball_possession	Kľzavý priemer percentuálneho držania lopty domácim tímom v head-to-head zápasoch na ihrisku hostí

Tabuľka B.1: Prehľad príznakov s ich popismi

Príznak	Hráč 1
ht_h2h_at_total_shots	Kľzavý priemer celkového počtu striel domáceho tímu v head-to-head zápasoch na ihrisku hostí
ht_h2h_at_shots_on_goal	Kľzavý priemer striel na bránku domáceho tímu v head-to-head súbojoch na ihrisku hostí
ath_h2h_total_shots_on_goal	Kľzavý priemer celkového počtu striel na bránku hostí v head-to-head súbojoch
at_h2h_ht_shots_on_goal	Kľzavý priemer striel na bránku hostí v head-to-head súbojoch na domácom ihrisku
ath_h2h_diff_shots_on_goal	Kľzavý priemer rozdielu striel na bránku hostí v head-to-head súbojoch
st_total_goals_ma_c	Krátkodobý kľzavý priemer celkového počtu inkasovaných gólov na zápas

Tabuľka B.2: Prehľad príznakov s ich popismi.

Príznačky spomenuté v tejto práci sú uvedené v tabuľke B. Kompletný zoznam príznakov je dostupný vo formáte CSV na cloudovom úložisku, ktorého odkaz je: https://drive.google.com/file/d/1hP28LD5NbcTGb3gGVtLJc4XpE-c71S8E/view?usp=drive_link a na priloženom médiu (SD disku).